

MOSAIC 0.3 — Micro-skill Orchestration through Skill Activation and Instruction Composition: uma arquitetura mínima para compor micro skills sobre ferramentas gerais

MOSAIC 0.3 — Micro-skill Orchestration through Skill Activation and Instruction Composition: a minimal architecture for composing micro-skills over general-purpose tools

João Vitor Scheuermann

MOSAIC 0.3 — 30 de agosto de 2026 / 30 August 2026

Documento técnico de arquitetura com evidência diagnóstica de planejamento. Esta versão revisa o núcleo conceitual do MOSAIC; ainda não apresenta validação end-to-end.

RESUMO

Este artigo especifica a MOSAIC 0.3 (Micro-skill Orchestration through Skill Activation and Instruction Composition), uma arquitetura mínima para agentes de linguagem que combinam micro skills, tools executáveis e a capacidade cognitiva do modelo. A revisão 0.3 altera o feedback pré-execução: depois de um P0 independente do catálogo, o runtime recupera candidatas por objetivo, reranqueia seus bodies completos, aplica um gate semântico global com decisões `keep` ou `drop` e entrega ao planejador somente os bodies canônicos mantidos, sem convertê-los em hints. P1 é então revisado uma única vez e o roteamento final volta a ocorrer independentemente para cada objetivo pronto. O perfil preserva bundles ordenados, menus compostos, observações criadas pelo runtime, revisão localizada e entrega determinística. Três laboratórios diagnósticos motivam a mudança: bodies completos foram preferidos a hints em 12 contra 3 avaliações, a revisão P0–P1 foi preferida ao planejamento direto e gates conservadores mantiveram vantagem agregada de qualidade sobre o contexto integral. Em uma auditoria adicional de 30 casos com rótulos exaustivos, retrieval híbrido e gate recuperaram 65/65 skills esperadas, removeram 300/310 ocorrências de ruído e retiveram 78/79 ocorrências relevantes. Esses resultados validam localmente retrieval e seleção, mas ainda não demonstram que o P1 filtrado melhora tarefas completas. **Palavras-chave:** agentes de linguagem; micro skills; planejamento; seleção semântica; uso de ferramentas; evidência causal; revisão localizada.

ABSTRACT

This article specifies MOSAIC 0.3 (Micro-skill Orchestration through Skill Activation and Instruction Composition), a minimal architecture for language agents that combine micro-skills, executable tools, and the model’s cognitive capability. Version 0.3 changes pre-execution feedback: after a catalog-independent P0, the runtime retrieves candidates per goal, reranks their complete bodies, applies one global semantic gate with `keep` or `drop` decisions, and gives the

planner only the retained canonical bodies without converting them into hints. P1 is revised once, after which final routing runs independently for each ready goal. The profile retains ordered bundles, composed tool menus, runtime-created observations, localized revision, and deterministic final delivery. Three diagnostic planning labs motivate this change: complete bodies were preferred to hints in 12 versus 3 evaluations, P0–P1 revision was preferred to direct planning, and conservative gates retained an aggregate quality advantage over the full context. In an additional 30-case audit with exhaustive labels, hybrid retrieval and gating recovered 65/65 expected skills, removed 300/310 noise occurrences, and retained 78/79 relevant occurrences. These results locally validate retrieval and selection, but do not yet show that filtered P1 improves complete tasks. **Keywords:** language agents; micro-skills; planning; semantic selection; tool use; causal evidence; localized revision.

1 INTRODUÇÃO

1.1 Problema

Agentes baseados em modelos de linguagem costumam receber dois tipos de extensão. O primeiro é composto por instruções reutilizáveis que ensinam um modo de trabalhar. O segundo é composto por operações executáveis que permitem ler dados, calcular valores, criar artefatos ou produzir efeitos externos. Neste artigo, o primeiro tipo é chamado de *skill* e o segundo de *tool*. A distinção parece simples, mas frequentemente desaparece na arquitetura. Uma *skill* é tratada como se fosse uma API; uma *tool* é tratada como se contivesse o método completo para resolver uma tarefa; e o plano acaba sendo construído como uma sequência de chamadas. Esse desenho funciona para pedidos estreitos, como enviar uma mensagem pronta a um canal. Ele é menos adequado para tarefas abertas. Considere o pedido:

Leia o último relatório financeiro, interprete os resultados e retorne a melhor oportunidade.

O pedido contém pelo menos quatro tipos de trabalho: localizar o documento correto, disponibilizar seu conteúdo, interpretar evidências e comparar alternativas. Localização e leitura dependem de operações externas. Interpretação, síntese e decisão podem ser realizadas pelo modelo, desde que ele receba instruções adequadas. Criar *tools* artificiais como `interpret_financial_report` ou `choose_best_opportunity` apenas deslocaria para uma API o raciocínio que o modelo continuaria precisando executar. O problema tratado pelo MOSAIC é, portanto:

*Como planejar por resultados e compor várias instruções comportamentais sobre *tools* gerais ou específicas, sem exigir uma relação um-para-um entre objetivo, *skill* e *tool*?*

1.2 Princípio de redução

A arquitetura segue uma regra de design deliberada: um componente só pertence ao núcleo quando é necessário para expressar a hipótese central. É fácil acrescentar registros, políticas, resolvedores, verificadores e camadas de compatibilidade; o trabalho de projeto está em retirar aquilo que não altera o conceito. Esse critério produz duas consequências. Primeiro, o artigo especifica um núcleo pequeno, e não uma plataforma operacional completa. Segundo, elementos úteis em produção não são negados; apenas deixam de ser pré-requisitos conceituais. Uma implementação futura pode acrescentar segurança, isolamento, observabilidade, retries de infraestrutura, provedores ou otimização, desde que haja uma razão concreta para isso.

1.3 Contribuições da especificação

A contribuição da MOSAIC não é um novo algoritmo de embeddings, um novo modelo de linguagem ou um novo protocolo de tool calling. A proposta é uma organização arquitetural com sete decisões centrais.

Quadro 1 - Decisões centrais da MOSAIC 0.3

Decisão	Efeito arquitetural
Planejar por objetivos orientados a resultados	A granularidade do plano não copia tools nem arquivos de skills.
Filtrar o feedback de P0 e preservar full bodies em P1	Um gate semântico reduz ruído sem substituir instruções canônicas por resumos.
Tratar skills como instruções e tools como operações	O modelo continua responsável por interpretação, transformação e decisão.
Selecionar bundles ordenados de zero a várias skills	Um objetivo combina comportamentos complementares sem virar vários nós.
Formar o menu por T_{base} e pelas tools do bundle	Um bundle vazio pode usar operações gerais sem exigir uma skill artificial.
Capturar observações no runtime	Cada retorno serializável de tool executável vira evidência ordenada com ID opaco; critérios citam IDs locais ou causalmente projetados.
Associar revisão ao conjunto completo de evidências	Uma revisão localizada recebe todas as observações do nó e preserva os resultados já concluídos.

Fonte: elaboração própria (2026).

1.4 Escopo e modelo de confiança

A MOSAIC 0.3 é uma especificação técnica, não uma implementação de produção. A especificação assume:

- catálogo de skills confiável; • registro de tools confiável; • execução em modo YOLO, sem uma fronteira de autorização definida pelo artigo; • modelo capaz de seguir instruções, produzir saídas estruturadas e chamar tools; • estado suficiente para preservar resultados e observações entre objetivos.

Não fazem parte do núcleo: defesas contra prompt injection, sandbox, least privilege, confirmação de efeitos, política de credenciais, retries e recuperação de infraestrutura, idempotência, compensação de ações, execução distribuída, scripts e recursos auxiliares de Agent Skills, treinamento de retrievers e implementação de código. A evidência diagnóstica da Seção 9 informa a revisão arquitetural, mas uma campanha end-to-end, significância estatística e generalização entre modelos permanecem fora do que este artigo demonstra. A correção limitada de uma saída estruturada semanticamente inválida não é retry de infraestrutura: ela pertence à fronteira de conformidade do runtime definida na Seção 4.2.

1.5 Status normativo e versão do perfil

Este documento define a **MOSAIC 0.3**. Os verbos *deve* e *não deve* indicam requisitos de conformidade; *pode* indica uma opção permitida; exemplos e justificativas são informativos. A especificação não prescreve linguagem, biblioteca, provedor de modelo ou protocolo de tool calling. Ela prescreve os objetos, a autoria de cada objeto e os invariantes necessários para comparar implementações.

A versão 0.3 substitui a etapa de hints da 0.2 no nível da especificação. Uma implementação que ainda extraia `SkillHint` deve declarar conformidade 0.2 ou uma variante própria até implementar o gate de planejamento e os contratos desta revisão. Os laboratórios da Seção 9 são instrumentos diagnósticos e não fazem parte do contrato de execução.

2 TRABALHOS RELACIONADOS

2.1 Agent Skills

A especificação Agent Skills define uma skill como um diretório que contém ao menos um arquivo `SKILL.md`, formado por frontmatter YAML e body em Markdown. `name` e `description` são obrigatórios; `allowed-tools` é opcional e experimental. A especificação também prevê `scripts/`, `references/` e `assets/`, carregados por divulgação progressiva quando necessários (AGENT SKILLS, 2026). O MOSAIC adota o arquivo `SKILL.md` como fonte canônica, mas define um perfil reduzido. O núcleo lê `name`, `description`, `allowed-tools` e o body. Os diretórios opcionais continuam válidos no ecossistema Agent Skills, porém não são necessários para a arquitetura descrita neste artigo e, por isso, ficam fora do perfil central.

Essa delimitação evita afirmar compatibilidade operacional com recursos que o executor

mínimo não carrega. O objetivo é compatibilidade no nível da representação de instruções, não uma implementação completa de todos os recursos do padrão.

2.2 SkillRouter e SkillRet

O SkillRouter investiga roteamento em catálogos grandes e mostra que o body da skill contém sinal decisivo para distinguir itens funcionalmente próximos. Sua arquitetura usa recuperação de alta cobertura seguida de reranking que lê o conteúdo integral da skill (ZHENG et al., 2026). O SkillRet amplia o problema de retrieval para uma biblioteca realista de milhares de skills e reforça que selecionar instruções relevantes em catálogos grandes é uma tarefa própria, distinta do uso de tools (CHO; KANG; KIM, 2026). O MOSAIC incorpora uma exigência arquitetural desses trabalhos: o segundo estágio de seleção deve ser body-aware. A proposta não exige um retriever específico. Busca lexical, embeddings, modelos treinados ou combinações híbridas são alternativas de implementação. O requisito conceitual é que o roteamento final não dependa apenas do nome e da descrição.

2.3 SkillWeaver

O SkillWeaver formaliza a composição de skills por meio de decomposição, retrieval e construção de um DAG. Sua Skill-Aware Decomposition devolve ao planejador sinais do catálogo para corrigir a decomposição inicial (GAO, 2026). Essa interação entre planejamento e retrieval é adotada pelo MOSAIC. A diferença está na unidade de composição. No SkillWeaver, a decomposição procura subtarefas atômicas associadas a skills individuais. No MOSAIC, o nó representa um resultado intermediário e pode receber um bundle de instruções. O feedback do catálogo pode revelar um resultado ausente ou uma dependência inadequada, mas não deve transformar cada skill candidata em um novo nó.

2.4 ReAct e Toolformer

ReAct organiza a resolução de tarefas como uma alternância entre decisão, ação e observação, permitindo que novas informações mudem os próximos passos (YAO et al., 2023). Toolformer explora quando chamadas de APIs acrescentam informação ou capacidade externa ao modelo (SCHICK et al., 2023). Ambos sustentam uma separação útil: o modelo interpreta e decide; a tool executa uma operação com contrato observável. O MOSAIC usa essa separação dentro de cada objetivo. O executor pode produzir o resultado diretamente ou alternar chamadas de tools e observações até que os critérios de conclusão sejam atendidos. Uma chamada de tool não se torna automaticamente um nó do plano.

2.5 Evidência recente sobre skills, bundles e menus de tools

SkillsBench trata skills como pacotes de conhecimento procedural e mostra que instruções focadas podem ser mais úteis do que documentação acumulada (LI et al., 2026). SkillMOO trata bundles como objetos passíveis de poda e substituição, reforçando que adicionar instruções indiscriminadamente não é equivalente a melhorar o agente (GONG et al., 2026). ToolMenuBench, por sua vez, transforma a construção do menu visível de tools em um problema de primeira classe (BABU; IYER, 2026).

Esses trabalhos ajudam a posicionar o MOSAIC, mas não são incorporados como novos componentes obrigatórios. Eles reforçam que retrieval, composição de instruções e construção do menu são fronteiras distintas.

2.6 Relevância pós-retrieval e ruído contextual

Reranking relativo responde qual candidata parece mais próxima da consulta, mas não decide se ela acrescenta utilidade material. O RE-RAG introduz um estimador que classifica se cada contexto recuperado é de fato útil, separando essa decisão da ordenação relativa (KIM; LEE, 2024). RAGChecker, por sua vez, avalia retrieval e geração como módulos distintos, evitando inferir qualidade da resposta apenas a partir da cobertura do retriever (RU et al., 2024). O gate pré-P1 do MOSAIC ocupa uma fronteira análoga: retrieval privilegia recall; a decisão semântica posterior estima utilidade operacional para o plano.

Essa separação também é motivada pelo efeito do ruído. Cuconasu et al. (2024) mostram que documentos de alto rank, mas sem resposta, podem prejudicar mais do que ruído aleatório. Amiraz et al. (2025) distinguem passagens irrelevantes benignas de distratores semanticamente próximos e mostram que seu efeito depende da consulta e do modelo. Para skills, a consequência é que similaridade lexical ou semântica não basta: uma candidata pode estar no tema correto e ainda introduzir um procedimento, formato ou artefato desnecessário.

2.7 Revisão condicionada por um plano inicial

Self-Refine condiciona uma segunda passagem na entrada original, na saída anterior e em feedback, obtendo melhora média de aproximadamente 20 pontos percentuais em sete tarefas (MADAAN et al., 2023). Em planejamento iterativo, DEPS também revisa planos iniciais a partir de evidência de execução (WANG et al., 2023). Esses resultados sustentam o padrão pedido original, rascunho e nova evidência, mas não isolam causalmente a presença do rascunho.

A ressalva é igualmente importante. Huang et al. (2024) mostram que autocorreção sem feedback externo confiável pode degradar raciocínio. Uma decomposição controlada mais recente separa ganhos da segunda passagem em nova resolução, scaffold e conteúdo do draft; drafts fracos podem prejudicar, enquanto drafts fortes ou estruturalmente úteis podem ajudar (NING; LI; YU, 2026). A MOSAIC, portanto, transporta P0 para P1 como rascunho falível,

não como autoridade. O pedido original permanece a fonte de escopo, e os bodies selecionados constituem evidência operacional nova.

Quadro 2 - Posição da MOSAIC em relação aos trabalhos-base

Trabalho	Unidade principal	Relação entre tarefa e skill	Decisão aproveitada pela MOSAIC
Agent Skills	arquivo ou diretório de instruções	ativação de uma skill	SKILL.md como fonte canônica
SkillRouter	consulta de retrieval	seleção e reranking de skills	body completo como sinal de roteamento
SkillWeaver	subtarefa atômica	uma skill por subtarefa	feedback de retrieval para a decomposição
ReAct	trajetória de ação e observação	não define catálogo de skills	revisão após observações
MOSAIC 0.3	objetivo orientado a resultado	zero, uma ou várias skills por objetivo	composição many-to-many e evidência capturada pelo runtime

Fonte: elaboração própria (2026).

3 MODELO CONCEITUAL

3.1 Vocabulário mínimo


A arquitetura usa os conceitos do Quadro 3.

Quadro 3 - Vocabulário normativo da MOSAIC 0.3

Conceito	Definição	Pergunta respondida
Pedido	Intenção, contexto e restrições fornecidos pelo usuário.	O que o usuário quer alcançar?
Objetivo	Resultado intermediário que deve existir ao final de uma parte da tarefa.	O que precisa estar verdadeiro?
Nó de objetivo	Objetivo inserido em um plano, com dependências, critérios e status.	Que unidade pode ser executada agora?
Skill	Instrução reutilizável que altera como o modelo executa um trabalho.	Que comportamento deve orientar o modelo?
Tool	Operação executável com nome, entrada e retorno observável.	Que ação concreta o runtime executa?
Bundle	Sequência ordenada de skills ativadas para um objetivo.	Que instruções atuam em conjunto e em que ordem?
Decisão do nó	Saída semântica do modelo: status, critérios com evidência e IDs opacos de observação, resultado, pedido de revisão e razão. Não contém objetos de observação nem <code>callId</code> .	O que o modelo concluiu semanticamente?
Observação	Registro criado pelo runtime para um retorno de tool executável, com ID opaco, correlação interna, nome, entrada, saída e ordem.	Que evidência operacional foi realmente retornada?
Resultado do nó	Decisão semântica validada pelo runtime; o ledger completo permanece exclusivamente no nó produtor.	Que decisão semântica o runtime aceita?
Pedido de revisão	Descrição semântica da suposição invalidada e do efeito solicitado, avaliada com todas as observações do nó.	Por que e com que efeito o plano deve mudar?
Estado projetado	Crítérios, observações citadas e artefatos dos ancestrais concluídos entregues ao objetivo atual, sem IDs do provedor.	Que resultados anteriores são relevantes para este nó?
Plano	DAG de nós de objetivo e dependências.	Em que ordem os resultados precisam existir?

Fonte: elaboração própria (2026).

Figura 1 – Separação de papéis entre pedido, objetivo, skill, modelo e tool



Fonte: elaboração própria (2026).

A separação da Figura 1 é normativa para a arquitetura. O objetivo descreve o resultado; a skill orienta o comportamento; a tool executa uma operação; o modelo decide como combinar esses elementos. Nenhum dos conceitos substitui os demais.

3.2 O que torna uma skill “micro”

“Micro” não significa uma única linha, uma única chamada ou uma única tool. Uma micro skill é pequena em responsabilidade, não necessariamente em número de passos. Ela deve atender a quatro propriedades:

1. **Coerência:** ensina uma preocupação comportamental identificável, como fundamentar afirmações em evidências ou comparar alternativas sob critérios explícitos. 2. **Reutilização:** pode ser aplicada a mais de um pedido ou objetivo sem depender de um workflow inteiro. 3. **Composição:** pode atuar ao lado de outras skills sem assumir controle exclusivo da tarefa. 4. **Carga integral:** seu body é conciso o suficiente para ser carregado completo quando selecionado.

`evidence-grounded-summary` é micro porque ensina como ligar afirmações a dados. `uncertainty-reporting` é micro porque ensina como explicitar premissas e limitações. `latest-document-reading` também pode ser micro mesmo usando `list` e `read`, pois sua responsabilidade coerente é identificar e disponibilizar o documento correto.

Em contraste, `financial-agent-that-does-everything` mistura descoberta, leitura, análise, decisão, redação e persistência. `use-read-when-reading` apenas repete o nome da tool e não acrescenta comportamento. O primeiro é amplo demais; o segundo é vazio demais.

3.3 Granularidade do objetivo

Um objetivo descreve um resultado, não uma sequência de operações. A frase “obter o relatório financeiro mais recente e válido” é um objetivo. A frase “chamar `list`, ordenar datas e chamar `read`” é uma trajetória de execução. Uma nova etapa é justificada quando pelo menos uma das condições abaixo ocorre:

- o resultado será consumido por outro objetivo;
- uma observação externa pode mudar o restante do plano;
- uma parte possui critério de conclusão próprio;
- duas partes podem ser executadas independentemente;
- o usuário pediu resultados ou artefatos separados.

A existência de uma tool ou de uma skill não é, sozinha, motivo para criar um nó. Listar arquivos, comparar nomes e ler um documento podem ocorrer dentro do mesmo objetivo. Da mesma forma, aplicar duas skills cognitivas ao mesmo conjunto de dados não exige dois objetivos.

Uma parte só é independente quando pode ser concluída sem revisar escolhas feitas em outro nó. Restrições que determinam conjuntamente a viabilidade — por exemplo, rota, hospedagem e orçamento — permanecem no mesmo objetivo. Uma escolha upstream não pode ser concluída antes da validação de restrições downstream capazes de invalidá-la. Produção e verificação semântica final também permanecem no mesmo nó por padrão; a verificação torna-se outro nó somente quando constitui um resultado independente solicitado pelo usuário.

3.4 Relações many-to-many

Considere um plano $P = (G, E)$, em que G é o conjunto de objetivos e E contém dependências acíclicas. Para cada objetivo g , o seletor produz um bundle ordenado:


$$B(g) = \langle s_1, \dots, s_k \rangle, \quad 0 \leq k \leq K_{\max}. \quad (1)$$

$K_{\max}$ é um limite pequeno configurado pelo runtime. Ele não define quantas skills existem no catálogo; apenas impede que um único objetivo acumule instruções demais. Cada skill s pode declarar um conjunto $A(s)$ de tools em `allowed-tools`. O menu visível para o objetivo é:

$$T(g) = T_{\text{base}} \cup \bigcup_{s \in B(g)} A(s). \quad (2)$$

T_{base} é o conjunto de tools gerais que o runtime decide expor a todos os objetivos. No perfil YOLO máximo, pode-se definir $T_{\text{base}} = T_{\text{registry}}$, tornando todas as tools registradas sempre visíveis. Em um perfil reduzido, `calculator` pode ser base enquanto integrações específicas, como `slack_send_message`, entram pelo bundle. A fórmula resolve um caso importante: se $B(g) = \emptyset$, o objetivo ainda pode usar T_{base} . Portanto, uma operação geral não exige uma skill artificial. Se nenhuma tool for necessária, o modelo conclui o objetivo cognitivamente.

Figura 2 – Relações many-to-many entre objetivos, micro skills e tools



Fonte: elaboração própria (2026).

A Figura 2 também mostra que uma skill pode orientar vários objetivos, que um objetivo pode combinar várias skills e que a mesma tool pode aparecer sob procedimentos diferentes. A semântica da operação permanece estável; o comportamento muda conforme o bundle.

3.5 Semântica do bundle ordenado

O bundle é uma sequência, não um conjunto sem ordem. O executor injeta bodies no contexto em uma ordem observável, e essa ordem pode afetar o modelo. Para evitar que duas implementações igualmente conformes usem convenções incompatíveis, o MOSAIC 0.3 define a regra mínima abaixo:

- o reranker produz uma ordem de aplicabilidade;
- o seletor percorre essa ordem e retém até $K_{\max}$ skills que acrescentem comportamentos distintos e necessários;
- a ordem final do bundle preserva a posição do reranking entre as skills selecionadas;
- empates de score são resolvidos pelo nome canônico da skill em ordem lexicográfica crescente;
- skills redundantes, conflitantes ou fora do objetivo são omitidas;
- o seletor pode retornar uma sequência vazia.

Na MOSAIC 0.3, a ordem de aplicabilidade é deliberadamente usada como ordem de composição. Essa é uma convenção de referência, não uma afirmação de que ela seja ótima. Uma extensão pode adotar precedência mais rica, desde que declare outra versão. Os bodies devem ser delimitados pelo nome canônico da skill para impedir fusão acidental entre instruções adjacentes.

4 ARQUITETURA MÍNIMA

4.1 Visão geral


A MOSAIC 0.3 possui seis estágios de runtime, alimentados por um catálogo canônico e conectados por um estado compartilhado:

1. planejador de objetivos;
2. retrieval preliminar, gate semântico e revisão única do plano inicial;
3. roteador final de skills e seletor de bundle;
4. montagem do menu de tools;
5. executor do nó;
6. compositor final determinístico.

O estado preserva resultados e observações criadas pelo runtime. Para cada nó, o modelo produz apenas uma decisão semântica. O runtime correlaciona cada chamada executável ao retorno correspondente, cria observações na ordem dos resultados e mantém o ledger completo no nó produtor, sem duplicá-lo no resultado semântico ou em terminações do runtime. Quando uma dessas evidências invalida uma suposição estrutural, o planejador revisa somente a parte não concluída do plano. O compositor final

não realiza uma segunda síntese: ele apenas entrega os resultados que já foram produzidos por objetivos terminais.

Figura 3 - Arquitetura mínima da MOSAIC 0.3



Fonte: elaboração própria (2026).

A Figura 3 separa duas responsabilidades. O catálogo prepara representações para busca; o runtime transforma um pedido em resultados. O catálogo não define a granularidade do plano, e o planner não escolhe tools diretamente.

4.2 Fronteira transversal de saída estruturada

JSON Schema expressa apenas a projeção estrutural representável de um contrato. Contratos da MOSAIC também contêm invariantes relacionais e semânticas que podem não aparecer nessa

projeção: dependências devem referenciar nós existentes, o grafo deve ser acíclico, entregáveis devem ser terminais e seleções devem respeitar o objetivo, as candidatas e os limites correntes. Portanto, a aceitação estrutural de uma resposta pelo provider não implica conformidade com o contrato da MOSAIC.

Toda saída estruturada escrita pelo modelo deve ser validada localmente pelo runtime contra o contrato completo antes de alterar plano ou estado. Essa fronteira aplica-se ao planejamento P0 e P1, ao gate semântico de planejamento, à seleção do bundle, à decisão semântica do nó e à revisão localizada. Uma submissão ausente, malformada ou inválida deve ser descartada integralmente, sem mutação parcial nem execução de chamadas apresentadas junto dela. O runtime pode fornecer feedback diagnóstico limitado, sem repetir o payload rejeitado, e solicitar correção dentro de um orçamento finito. Uma resposta corrigida válida pode então ser aceita atomicamente; o esgotamento do orçamento deve causar falha.

O perfil recomendado representa o contrato completo como uma tool terminal reservada. O runtime intercepta seus argumentos, valida-os localmente e nunca executa essa tool nem a registra como *Observation*. Esse protocolo é provider-independent e evita depender de structured output nativo. Outros protocolos são conformes quando preservam a mesma validação completa, atomicidade, feedback limitado e recuperação limitada. A correção de conformidade semântica é responsabilidade do runtime; retransmissão, backoff e recuperação de falhas de transporte ou provider continuam fora do núcleo.

4.3 Catálogo canônico e índice body-aware

Cada skill é representada por um `SKILL.md`. O núcleo mantém somente os dados necessários para recuperação e execução:

- `name`;
- `description`;
- `body` completo;
- lista normalizada de `allowed-tools`;
- texto de indexação derivado deterministicamente desses campos.

O carregamento do catálogo é *fail-fast* para os campos normativos da MOSAIC 0.3. A implementação deve rejeitar o catálogo quando houver nome de skill duplicado, campo obrigatório ausente, `body` vazio ou nome de tool declarado que não exista em Registry. Tools repetidas em uma mesma skill são deduplicadas. Campos desconhecidos podem ser preservados, mas não alteram o núcleo. Uma versão anterior da arquitetura previa um compilador baseado em modelo para inferir `useWhen`, `behaviors`, `outputs` e outros campos. Esse componente foi removido do núcleo. A recuperação body-aware já pode operar sobre `name`, `description` e `body`; o re-ranker lê a fonte original. Metadados inferidos podem ser úteis em implementações específicas, mas não são necessários para expressar a composição. O índice pode ser lexical, vetorial ou híbrido. O MOSAIC não fixa o mecanismo. A única exigência é preservar um caminho do resultado de retrieval até o body canônico, pois o reranking e a execução dependem das instruções reais, não apenas de resumos derivados.

4.4 Planejamento inicial por resultados

O planejador recebe o pedido e produz um DAG inicial P_0 . Nessa primeira passagem, ele não recebe nomes de skills. Isso reduz a tendência de copiar a estrutura física do catálogo. Cada nó deve possuir:

- identificador único no plano; • objetivo orientado a resultado; • dependências que referenciam apenas IDs existentes; • critérios `doneWhen`; • status inicial `pending`.

Para o pedido financeiro, um plano inicial plausível é:

1. obter o relatório mais recente e válido; 2. interpretar os resultados relevantes; 3. comparar oportunidades; 4. redigir a resposta.

O planner não precisa antecipar chamadas como `list`, `read` ou `calculator`. Essas decisões pertencem ao executor de cada nó.

P_0 e P_1 obedecem à mesma fronteira semântica: toda afirmação relevante do campo `goal` deve aparecer explicitamente em ao menos um critério `doneWhen`; decisões acopladas não são separadas apenas porque podem usar operações diferentes; e nenhum nó upstream pode declarar conclusão antes de verificar restrições dependentes que possam invalidar sua escolha. O feedback body-aware pode corrigir uma divisão artificial, mas não autoriza replanejamento global durante a execução.

4.5 Retrieval preliminar, gate semântico e revisão única

Depois de P_0 , o runtime executa retrieval preliminar para cada objetivo. A consulta combina o pedido original, o resultado desejado e seus critérios `doneWhen`. O primeiro estágio privilegia cobertura; o segundo reranqueia as candidatas lendo o body completo. Um limite positivo K_{plan} restringe quantas candidatas reranqueadas de cada objetivo podem entrar no contexto de seleção. Um threshold de score pode atuar como limite defensivo, mas não substitui a decisão semântica descrita abaixo.

As candidatas aprovadas por ao menos um objetivo são unidas pelo nome canônico. Cada item preserva os objetivos que o recuperaram, sua posição e seu score para auditoria. Seja C_0 essa união ordenada. O gate de planejamento recebe o pedido, P_0 e os bodies completos de C_0 , avalia cada candidata exatamente uma vez e produz apenas `keep` ou `drop`, uma rationale por candidata e uma rationale global:

$$F_0 = \Gamma(q, P_0, C_0), \quad F_0 \subseteq C_0. \quad (3)$$


`keep` significa que P_1 provavelmente ficaria menos completo, preciso, viável, executável ou verificável sem aquela instrução. `drop` exige alta confiança de que o body não acrescenta valor material, duplica uma contribuição já mantida, conflita com o pedido ou introduz trabalho não sustentado. Similaridade temática, rank ou a mera menção do mesmo assunto em P_0 não bastam para manter nem remover uma skill. Quando a utilidade material permanece incerta, o

gate favorece *keep*; a minimização ocorre somente depois de preservar contribuições distintas.

O planner recebe o pedido original, P_0 e os bodies canônicos completos das skills de F_0 , na ordem preservada, e produz um P_1 completo depois de uma única revisão. P_0 é um rascunho falível, não uma autoridade nem um contrato de edição mínima. O planner deve confrontar cada objetivo com o pedido e pode remover, fundir, dividir, rearranjar ou reescrever qualquer parte, inclusive quando nenhum body contesta explicitamente o rascunho. O pedido é a única fonte de escopo e de entregáveis solicitados. Os bodies são orientação operacional: podem acrescentar métodos e critérios de verificação materialmente aplicáveis, mas não devem criar entregáveis ou ampliar o escopo sem sustentação no pedido.

As rationales do gate são evidência de auditoria: não viram hints, não reescrevem bodies e não entram no contexto de revisão. Quando $F_0 = \emptyset$, o runtime pode materializar P_1 como uma cópia validada de P_0 , com revisão 1, sem uma chamada cognitiva vazia, desde que P_0 continue satisfazendo o pedido. Depois de P_1 , o roteamento é executado novamente para os objetivos finais.

Figura 4 - Feedback pré-execução da MOSAIC 0.3



Fonte: elaboração própria a partir dos experimentos diagnósticos (2026).

A regra de controle permanece simples: uma skill pode revelar que “analisar” e “resumir” são resultados semanticamente diferentes, mas sua mera existência não cria um nó. O catálogo informa o planner; não governa sua granularidade. O gate limita o contexto de planejamento, não o catálogo disponível para execução.


4.6 Roteamento final, reranking e seleção do bundle

Para cada objetivo pronto, o roteador constrói uma consulta com:

- descrição do objetivo;
- critérios `doneWhen`;
- termos relevantes do pedido original;
- saídas necessárias dos objetivos anteriores.

O primeiro estágio privilegia cobertura e retorna até K_{retrieve} candidatas. O segundo compara as candidatas usando o body completo. Em seguida, o seletor percorre a lista reranqueada e retém, até K_{max} , apenas as skills que acrescentam comportamentos distintos e necessários.

Figura 5 - Semântica mínima da seleção de bundle



Fonte: elaboração própria (2026).

A seleção é baseada no comportamento ensinado pela skill. Uma skill não deve ser escolhida apenas porque declara uma tool útil. Se uma operação geral já estiver em Tbase, ela continua disponível mesmo quando nenhuma skill é selecionada.

O gate de planejamento e o seletor de bundle usam o mesmo princípio de utilidade, mas possuem escopos diferentes. Γ opera uma vez sobre a união das candidatas de P_0 para controlar o feedback entregue a P_1 . $B(g)$ opera depois de P_1 , por objetivo pronto, usando seus critérios e estado causal para compor a execução. Uma decisão `drop` em Γ não proíbe recuperação posterior, e uma decisão `keep` não força presença no bundle. Essa independência permite que P_1 altere a decomposição sem congelar prematuramente o roteamento de execução.

4.7 Montagem do menu de tools

Após a seleção, o runtime calcula $T(g)$ pela fórmula apresentada anteriormente. Não existe um tool router independente no núcleo. Essa remoção é deliberada: um segundo roteador duplicaria a decisão de relevância antes que a hipótese básica fosse demonstrada.

Quadro 4 - Exemplos de montagem do menu de tools

Configuração	Bundle	Menu resultante
$T_{\text{base}} = \{\text{calculator}\}$	vazio	$\{\text{calculator}\}$
$T_{\text{base}} = \{\text{calculator}\}$	latest-document-reading declara <code>list</code> e <code>read</code>	$\{\text{calculator}, \text{list}, \text{read}\}$
$T_{\text{base}} = \{\text{calculator}\}$	slack-message declara <code>slack_list_channels</code> e <code>slack_send_message</code>	união das três tools
YOLO máximo: $T_{\text{base}} = T_{\text{registry}}$	qualquer	todas as tools registradas

Fonte: elaboração própria (2026).

`allowed-tools` é, neste perfil, um vínculo declarativo entre skill e menu de execução. Não é tratado como fronteira de autorização ou política de segurança.

4.8 Montagem do contexto e projeção de estado

O executor recebe somente o contexto necessário para o objetivo atual. A montagem deve seguir a ordem estável abaixo:

1. instruções do runtime; 2. pedido original e restrições globais; 3. objetivo atual e seus critérios `doneWhen`; 4. estado projetado; 5. bodies das skills do bundle, cada um entre delimitadores que contenham o nome canônico; 6. schemas das tools de $T(g)$.

Por padrão, o estado projetado de um objetivo contém, para cada ancestral transitivo concluído:

- status e evidência de cada critério;
- IDs opacos das observações citadas;
- quantidade total e quantidade citada de observações;
- ID, nó produtor, nome, entrada e saída somente das observações citadas;
- artefatos atuais, representados normativamente como conteúdo inline ou como referência opaca.

IDs repetidos entre critérios são materializados uma única vez e as observações citadas preservam sua ordem original no ledger do ancestral produtor. `callId`, observações não citadas e trajetórias de ramos sem relação causal permanecem fora do contexto. O resultado textual declarado pelo ancestral é evidência, mas não substitui a inspeção direta de um estado produzido quando o descendente dispõe de uma tool capaz de observá-lo.

Todo artefato possui um discriminador `kind` e um MIME type não vazio. A variante `inline` contém `data`, que pode ser vazio; a variante `reference` contém uma string `reference` não vazia. A projeção preserva a ordem e apresenta referências como referências, nunca como se fossem conteúdo. O núcleo apenas valida e transporta a string opaca: resolução, checagem de existência, persistência, armazenamento e autorização permanecem fora do perfil.

Resultados de ramos sem dependência causal com o objetivo atual são omitidos, salvo quando o plano os referencia explicitamente. Essa regra reduz contexto e torna a projeção audível sem introduzir um novo subsistema de memória.

4.9 Executor do nó

O modelo pode concluir diretamente ou chamar tools. Cada retorno serializável de tool executável volta ao mesmo nó e é registrado pelo runtime como uma `Observation` com UUID opaco; a tool reservada para a saída estruturada terminal nunca é uma observação. Chamadas rejeitadas antes da execução, handlers que lançam e resultados não serializáveis também não entram no ledger; resultados válidos que representam falha operacional entram normalmente. A decisão final do modelo contém somente status, avaliações ordenadas de `doneWhen`, resultado, pedido semântico de revisão e razão. Cada avaliação contém `criterionIndex`, `satisfied`, evidência em prosa e `observationIds`. Esses IDs são não vazios, únicos dentro do critério e citam o menor subconjunto de observações locais ou ancestrais projetadas que comprova o critério. A lista vazia é válida quando a prova decorre somente do pedido ou de um resultado determinístico.


O runtime rejeita IDs vazios ou colidentes, cria o ledger ordenado no nó e somente então valida cada referência contra as observações locais e a projeção causal de ancestrais concluídos no grafo ativo. IDs inexistentes, duplicados no mesmo critério, pertencentes a outro ramo, descendente ou snapshot aposentado, ou ausentes do contexto apresentado ao modelo invalidam a decisão inteira antes do armazenamento do `NodeOutcome` ou da promoção de qualquer artefato. Uma decisão `completed` exige todos os critérios satisfeitos e resultado presente. Antes de concluí-la, o executor deve inspecionar, quando existirem, código de saída, `stderr`, `timeout` e truncamento. Um comando posterior bem-sucedido não resolve automaticamente uma falha anterior: uma nova observação deve comprovar o estado afetado. Quando todas as etapas de um comando shell composto são obrigatórias, a composição deve preservar falhas intermediárias, por exemplo com `set -e` ou `&&`.

L_{node} é um orçamento finito e positivo de turnos do modelo para cada nó, onde um turno

corresponde a uma invocação do modelo, independentemente de ela produzir resposta direta, saída terminal, uma ou várias chamadas de tools ou uma tentativa de reparo de saída estruturada. A implementação deve declarar o valor usado. O limite fornece vivacidade local, uso limitado de recursos e uma condição de execução reproduzível: uma mesma configuração não pode continuar solicitando indefinidamente novos passos do modelo. Tools solicitadas no último turno permitido podem concluir e suas observações devem ser preservadas no nó; o esgotamento é detectado antes de outra invocação e produz uma terminação que não duplica o ledger.

O esgotamento de L_{node} produz `blocked`, pois significa que o nó não obteve uma decisão terminal dentro do orçamento declarado, e não necessariamente uma falha operacional do modelo, do provedor ou de uma tool. Esse limite não substitui cancelamento, timeouts de tools, orçamentos de custo nem políticas separadas para autorizar, limitar ou compensar efeitos colaterais. Esses mecanismos tratam riscos distintos e podem encerrar uma execução antes do orçamento de turnos.

Figura 6 - Loop de execução e materialização do resultado do nó



Fonte: elaboração própria (2026).


4.10 Ciclo de vida do nó e revisão localizada

O status de um nó pode ser `pending`, `ready`, `running`, `completed`, `needs_revision`, `blocked` ou `failed`. Um nó `pending` torna-se `ready` quando todas as dependências estão `completed`. O scheduler o coloca em `running`. A satisfação de `doneWhen` leva a `completed`. Uma

decisão `needs_revision` descreve a suposição estrutural invalidada e o efeito solicitado. Esse status exige ao menos uma observação produzida pelo próprio nó. O pedido de revisão usa o ledger completo mantido no nó, ainda que o planner conclua depois que algumas observações são irrelevantes. Uma decisão semântica `blocked` exige evidência concreta de impossibilidade, alternativas razoáveis tentadas e consideração explícita de `needs_revision`. A ausência de confirmação explícita não prova impossibilidade quando os dados admitem uma interpretação válida. Falhas de provider, tool, schema ou correlação permanecem falhas operacionais distintas; o esgotamento de L_{node} continua sendo um bloqueio pertencente ao runtime.

Um `blocked` válido continua sendo propagado pelo scheduler aos dependentes. Nós concluídos não são reabertos neste perfil; revisão de ancestrais e execução parcial depois de bloqueio exigiriam uma extensão declarada.

Figura 7 – Máquina de estados mínima de um nó



Fonte: elaboração própria (2026).

Quando ocorre revisão, o planner recebe ID de observação, nome da tool, entrada e saída de cada observação em ordem, mas não recebe `callId`. Ele decide a relevância a partir da suposição invalidada e do efeito solicitado:


- objetivos `completed` permanecem concluídos e seus resultados permanecem no estado;
- somente o nó atual ainda incompleto e objetivos não iniciados podem ser retidos, substituídos, removidos ou inseridos;
- IDs de nós sobreviventes permanecem estáveis;
- dependentes de um nó removido devem ser removidos ou reconectados explicitamente;
- o plano revisado deve continuar acíclico e referenciar apenas IDs existentes;
- o nó atual pode ser mantido com o mesmo ID e reiniciado como `pending`, ou substituído quando a nova decomposição exigir outra unidade de resultado.

R_{max} limita o número de revisões localizadas em uma execução. O artigo não prescreve um valor universal; o runtime deve declarar o valor usado. Essa guarda impede ciclos infinitos sem transformar o núcleo em um protocolo completo de recuperação.

4.11 Composição da resposta final

Objetivos terminais produzem o conteúdo semanticamente final. Quando a tarefa exige síntese, redação ou decisão, o plano deve conter um objetivo terminal responsável por essa transformação, como G4 no exemplo financeiro. A função `compor_resposta` não chama o modelo e não aplica skills novamente. Ela seleciona resultados de nós terminais marcados para entrega, ordena-os de forma estável pela ordem topológica e empacota texto, artefatos inline ou referências opacas e efeitos observáveis. A ordem dos artefatos é preservada. A composição não resolve nem persiste referências. Assim, a resposta é produzida exatamente uma vez e o trace identifica qual objetivo realizou a síntese.

Figura 8 - Sequência de uma execução completa da MOSAIC 0.3



Fonte: elaboração própria (2026).

5 ALGORITMO CENTRAL

A arquitetura pode ser expressa pelo algoritmo abstrato abaixo. Ele especifica a ordem das decisões sem fixar linguagem, biblioteca, modelo ou protocolo de erros.

Algoritmo 1 - Execução da MOSAIC 0.3

```
entrada: pedido q, catálogo S, registro T_registry, base T_base,
        K_retrieve, K_plan, K_max, L_node e R_max

regra transversal para toda operação cognitiva estruturada:
    validar localmente o contrato completo antes de alterar plano ou
    ↪ estado
    descartar submissão inválida e fornecer somente feedback limitado
    aceitar correção em orçamento finito; se o orçamento esgotar, falhar

validar_catálogo_e_registro(S, T_registry, T_base)
P0 <- planejar_objetivos(q)           // sem nomes de skills
C0 <- uniao_canonica(
    para cada g em P0:
        recuperar_e_reranquear(g, q, vazio, S, K_retrieve, K_plan))
G0 <- filtrar_contexto_de_planejamento(q, P0, C0)
    // avaliar cada candidata exatamente uma vez: keep ou drop
F0 <- candidatas_mantidas(C0, G0)
se F0 estiver vazio:
    P <- copiar_como_P1(P0)           // revisão 1, sem chamada
    ↪ vazia
senão:
    P <- revisar_uma_vez(q, P0, bodies_canonicos(F0))
                                     // full bodies, sem
                                     ↪ hints

validar_dag(P)
estado <- vazio
revisoes <- 0

enquanto houver objetivo não terminal em P:
    wave <- objetivos prontos em ordem determinística

    para cada g em wave:
        C <- recuperar_e_reranquear(g, q, projetar_estado(g, P, estado),
                                     S, K_retrieve)
        B <- selecionar_bundle_ordenado(C, K_max)
        T <- T_base união tools_declaradas(B)
        projecao <- projetar_criterios_e_evidencias_citadas(g, P, estado)
        contexto <- montar_contexto(q, g, projecao, B, T)

    ledger, decisao, limite_esgotado <-
    ↪ executar_ate_decisao(contexto, L_node)
```

```

observacoes <- materializar_observacoes_com_ids_opacos(ledger)
// falhar se um ID estiver vazio ou colidir no storage do agente
// excluir a tool terminal usada somente para saída estruturada
anexar observacoes ao no produtor
se limite_esgotado:
  termination <- bloquear_por_limite_sem_duplicar_observacoes()
senão:
  validar_ids_locais_e_ancestrais(decisao, P, estado)
  outcome <- materializar(decisao)
  // referência inválida falha antes de armazenar outcome ou
  → promover artefato

preservar observacoes no estado na ordem da wave e dos retornos de
→ cada nó

para cada outcome da wave:
  se outcome.status = completed:
    promover(outcome.resultado)
  senão se outcome.status = needs_revision:
    exigir tamanho(no.observacoes) >= 1
    exigir revisoes < R_max
    P <- revisar_objetivo_atual_e_restantes(
      P, outcome.revisionRequest,
      evidencias_sem_callId(no.observacoes))
    validar_dag(P)
    revisoes <- revisoes + 1
  senão:
    registrar outcome como blocked ou failed

retornar compor_resposta_deterministicamente(q, P, estado)

```

O algoritmo mantém onze invariantes de conformidade:

1. objetivos descrevem resultados, não chamadas de tools nem nomes de skills; 2. decisões que precisam ser revistas em conjunto permanecem no mesmo objetivo; 3. o planner inicial não depende dos nomes das skills; 4. o gate pré-P1 avalia cada candidata única exatamente uma vez e entrega à revisão somente bodies canônicos mantidos, nunca hints ou rationales; 5. o roteamento final é independente do gate de planejamento; 6. o bundle pode conter zero, uma ou várias skills e possui ordem observável; 7. tools gerais podem existir fora das skills por meio de T_{base} ; 8. o body canônico é usado no feedback de P1, no reranking final e na execução; 9. toda operação cognitiva estruturada satisfaz o contrato completo do runtime antes de alterar plano ou estado; 10. toda observação executável é criada, correlacionada e ordenada pelo runtime, nunca pelo modelo, e cada critério cita apenas evidência causalmente disponível; 11. uma revisão

localizada recebe o conjunto completo de observações, preserva nós concluídos e altera apenas o nó atual incompleto e a parte ainda não iniciada do plano.

Uma implementação que preserve esses invariantes e os contratos do Apêndice A pode variar livremente em modelo, índice, linguagem, formato de serialização e protocolo de tool calling.

6 PERFIL MOSAIC 0.3 PARA SKILL.MD

6.1 Subconjunto suportado

O perfil mínimo usa o subconjunto do Quadro 5.

Quadro 5 - Elementos de SKILL.md na MOSAIC 0.3

Elemento	Tratamento na MOSAIC 0.3
name	obrigatório; identificador único da skill
description	obrigatória; sinal inicial de retrieval
allowed-tools	opcional; normalizado para lista de nomes de tools
body Markdown	obrigatório; fonte principal de roteamento e instrução
license, compatibility, meta- data	podem ser preservados, mas não alteram os contratos normativos
scripts/, references/, assets/	fora da especificação mínima

Fonte: elaboração própria (2026).

6.2 Gramática e normalização de allowed-tools

A forma canônica do MOSAIC é uma sequência YAML:

```
allowed-tools:
```

```
- calculator  
- read
```

Para compatibilidade de ingestão, uma implementação pode aceitar um escalar com nomes separados por espaços, como `allowed-tools: list read`. O parser deve normalizar as duas formas para `string[]`, remover duplicatas e preservar a ordem de primeira ocorrência. Nomes de tools são identificadores exatos, sensíveis a caixa quando o registro também o for. Uma referência que não resolva em Tregistry invalida o carregamento do catálogo.

6.3 Estrutura recomendada do body

O formato do body permanece livre, mas uma micro skill legível tende a responder cinco perguntas:

1. qual comportamento ela ensina; 2. quando deve ser usada; 3. quando não deve ser usada; 4. qual procedimento ou critério deve ser seguido; 5. como reconhecer a conclusão.

Uma estrutura recomendada é:

```
# Nome legível

## Purpose
Explique a preocupação comportamental da skill.

## Use this skill when
- descreva situações aplicáveis.

## Do not use this skill when
- descreva situações não aplicáveis.

## Procedure
1. descreva o método ou os critérios.

## Completion
Descreva o resultado esperado.
```

Os títulos não são obrigatórios. O requisito é semântico: o body precisa acrescentar comportamento que o nome da tool ou uma descrição genérica não expressam.

6.4 Exemplo cognitivo com tool opcional

```
---
name: financial-analysis
description: Interprets reported financial results, compares periods,
and identifies material business changes. Use when financial evidence
must be understood rather than merely copied.
allowed-tools:

- calculator
---

# Financial Analysis
Compare period, units, revenue, margins, cash generation and material
```

costs.
Separate recurring changes from one-time events.
Connect claims to reported figures and state missing information.
Use calculator only when a derived metric is necessary.
Completion: the main changes, their evidence and the principal
limitation
are explicit.

A skill continua cognitiva: seu principal valor é o método de análise. calculator apenas acrescenta uma operação possível.

6.5 Exemplo de uma skill com várias tools

```
---
name: latest-document-reading

description: Finds and reads the most relevant recent document. Use
  ↳ when

the user asks for the latest report, memo, statement or specification.
allowed-tools:

- list
- read
---
```

Latest Document Reading
Identify the requested document type and period.
List plausible candidates, compare dates and status markers, then
↳ read

enough
content to confirm the correct document before returning its content
reference.
Completion: the selected document matches the requested type and
↳ period,
and the required content is available to the next objective.

A skill orienta várias chamadas possíveis sem criar vários nós. list, leituras parciais e leitura final pertencem ao mesmo resultado: disponibilizar o documento correto.

6.6 Semântica de `allowed-tools`

No MOSAIC, `allowed-tools` significa:

Quando a skill está ativa, os nomes declarados são adicionados ao menu de tools do objetivo.

A lista não descreve o propósito da skill, não substitui o body e não deve ser o único critério de seleção. Duas skills podem declarar `read` e ensinar comportamentos diferentes. Uma tool pode estar em Tbase e também aparecer em `allowed-tools`; a união remove duplicatas. Essa semântica é funcional, não securitária. O artigo assume que o catálogo e o registro são confiáveis e não define permissões, confirmação ou isolamento.

7 EXEMPLOS DE COMPOSIÇÃO

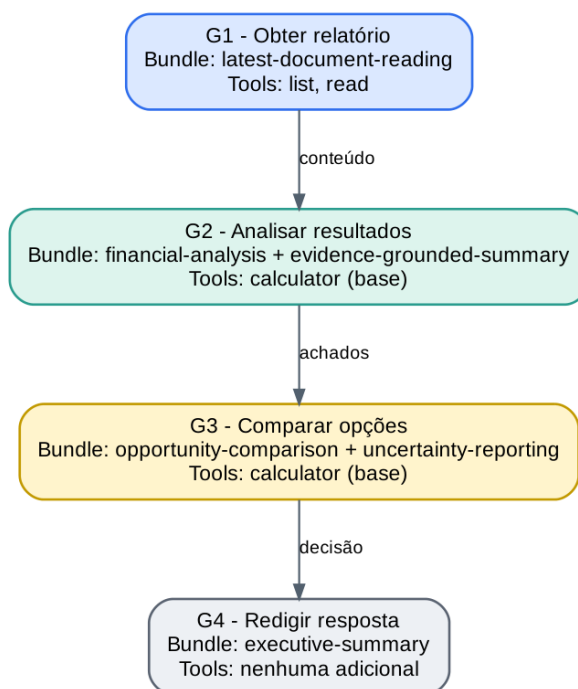
7.1 Exemplo financeiro de ponta a ponta

Pedido:

Leia o último relatório financeiro, interprete os resultados e retorne a melhor oportunidade.

Considere $T_{base} = \{\text{calculator}\}$. O plano possui quatro objetivos.

Figura 9 – Plano, bundles e tools do exemplo financeiro



Fonte: elaboração própria (2026).

No primeiro objetivo, `latest-document-reading` acrescenta `list` e `read`. O executor pode listar arquivos, ler cabeçalhos e confirmar o documento sem transformar cada chamada em um nó. No segundo objetivo, duas skills orientam a mesma análise: uma fornece o método financeiro; outra exige que os achados permaneçam ligados às evidências. `calculator` está disponível por ser base, mas seu uso não é obrigatório. O terceiro objetivo usa duas skills cognitivas para gerar e comparar alternativas sob incerteza. O quarto organiza a comunicação e produz o conteúdo final. Depois de G4, o compositor apenas empacota o resultado de G4; não executa nova síntese.

7.2 Bundle vazio com tool base

Pedido:

Leia o valor bruto da fixture invoice-028 e calcule 17,5% desse valor.

Considere $T_{\text{base}} = \{\text{read_fixture}, \text{calculator}\}$. O plano pode conter um único objetivo: “produzir o valor derivado correto”. O seletor pode retornar $B(g) = \emptyset$, porque ler um identificador conhecido e executar uma operação aritmética não exige um procedimento especializado. O menu permanece capaz de acessar um valor externo e calcular o resultado. Esse exemplo demonstra duas propriedades: skills não são pedágios obrigatórios para qualquer ação, e um caso de validação pode tornar a tool causalmente necessária ao esconder o valor da fixture do prompt. Um cálculo cujo operando já aparece no pedido ilustra apenas disponibilidade, não necessidade empírica de T_{base} .

7.3 A mesma tool sob skills diferentes

Quadro 6 - Reuso da mesma tool sob procedimentos diferentes

Objetivo	Skill	Comportamento acrescentado
identificar obrigações contratuais	<code>contract-analysis</code>	localizar partes, obrigações, prazos e exceções
explicar fluxo de autenticação	<code>source-code-explanation</code>	seguir módulos, chamadas e dependências
interpretar resultados financeiros	<code>financial-analysis</code>	identificar período, unidades, variações e materialidade

Fonte: elaboração própria (2026).

A operação é a mesma: disponibilizar conteúdo. A interpretação muda porque o bundle muda.

7.4 Uma skill, várias tools e várias chamadas

Pedido:

Encontre o relatório do segundo trimestre e leia as seções de receita e caixa.

Um único objetivo pode executar a trajetória:

```
list candidatos
-> read cabeçalho do arquivo A
-> read cabeçalho do arquivo B
-> selecionar o arquivo B
-> read seção de receita
-> read seção de caixa
-> concluir com uma referência ao conteúdo
```

O número de chamadas não determina o número de objetivos. O resultado intermediário relevante é “o conteúdo correto está disponível”.

7.5 Produção e persistência de um artefato

Pedido:

Escreva um README de instalação e salve em README.md.

O plano pode separar:

1. produzir o conteúdo do README; 2. persistir o conteúdo em README.md.

A separação não ocorre porque existe a tool `write`. Ela ocorre porque há dois resultados observáveis: conteúdo pronto e arquivo persistido. O primeiro objetivo pode usar `technical-document-writing` sem tools. O segundo pode usar `file-writing`, que declara `write`. Se o usuário pedisse apenas “escreva um README”, o segundo objetivo não existiria; a resposta seria entregue no chat.


8 DECISÕES DE REDUÇÃO E NÃO OBJETIVOS

Quadro 7 - Elementos removidos da especificação mínima

Elemento removido	Razão
Extração obrigatória de hints antes de P1	Nos diagnósticos, a compressão perdeu sinal procedural; a 0.3 filtra candidatas e preserva os bodies canônicos das skills mantidas.
Compilador por LLM com muitos campos inferidos	<code>name</code> , <code>description</code> e <code>body</code> já sustentam indexação e reranking.
Tool router independente	T_{base} e a união de <code>allowed-tools</code> resolvem o menu mínimo.
Camada de capabilities e providers	Nomes diretos de tools bastam enquanto não houver implementações equivalentes.
Resolvedor de <code>scripts/</code> , <code>references/</code> e <code>assets/</code>	O conceito é expresso carregando apenas <code>SKILL.md</code> .
Otimizador formal de bundles	Seleção ordenada, limite e critérios qualitativos são suficientes.
Linguagem formal de precedência	A ordem estável do reranking é a convenção da MOSAIC 0.3.
Verificador separado	<code>doneWhen</code> pode ser avaliado pelo executor na especificação mínima.
Protocolo completo de erros	Status de nó, limites e pedido semântico de revisão descrevem o fluxo central.
IDs do provedor em saídas do modelo	Correlação pertence ao runtime; o modelo não deve copiar referências opacas.
Segurança, autorização e prompt injection	A especificação assume catálogo, tools e runtime confiáveis em modo YOLO.
Scheduler distribuído e paralelismo formal	Um DAG expressa a ordem necessária sem infraestrutura adicional.

Fonte: elaboração própria (2026).

Figura 10 - Fronteira entre a MOSAIC 0.3 e extensões operacionais



Fonte: elaboração própria (2026).

A fronteira da Figura 10 não impede extensões. Ela estabelece uma ordem: primeiro, tornar a composição conceitualmente clara e implementável; depois, acrescentar mecanismos que casos reais justifiquem. Uma implementação endurecida pode envolver o MOSAIC com política, sandbox, filtragem de tools e observabilidade sem alterar a relação fundamental entre objetivo, bundle, menu e executor.

9 EVIDÊNCIA DIAGNÓSTICA PARA A REVISÃO 0.3

9.1 Escopo dos experimentos

A MOSAIC 0.3 é informada por três laboratórios privados de planejamento, sendo o terceiro estendido por uma auditoria exaustiva de seleção. Eles não executam tools nem tarefas completas; isolam a transição entre pedido, P0, retrieval, representação das skills, filtragem e P1. Os dois primeiros laboratórios e a fase comparativa do terceiro usam seis casos, três rodadas por caso, catálogo de 37 skills, o mesmo modelo de planejamento e dois juízes independentes. Cada comparação é apresentada cegamente nas duas orientações A/B; um resultado é inconsistente quando a preferência muda com a posição.

A extensão mais recente usa 30 casos autorados nos domínios de software, documentos e artefatos, finanças, viagens e computação científica. Em cada caso, as 37 skills do catálogo for-

mam uma partição exaustiva: `expected` identifica orientação necessária, `useful` identifica contribuição suplementar aceitável e `noise` classifica todo o restante como irrelevante, sem valor operacional ou conflitante. Esses rótulos são usados apenas no scoring offline e nunca entram em P0, retrieval, reranking, gate ou P1.

As rodadas repetidas dos experimentos comparativos não são tarefas independentes. Seus conjuntos de skills esperadas são incompletos e as preferências são produzidas por modelos, não por verificadores end-to-end. A auditoria de 30 casos elimina a ambiguidade entre skill suplementar e ruído no scoring, mas continua sendo um conjunto autorado, com um único run, um catálogo pequeno e um modelo de gate. Portanto, os números abaixo sustentam decisões locais de arquitetura e revelam modos de falha; não estabelecem superioridade universal nem significância confirmatória.

9.2 Full bodies, P0 e revisão

O primeiro laboratório comparou duas revisões do mesmo P0 com as mesmas skills. Uma recebeu os bodies completos; a outra recebeu hints extraídas por uma chamada intermediária e classificadas como vocabulário, lacuna, divisão, dependência ou execução. Em 18 avaliações cegas, o resultado foi:

Quadro 8 - Full body versus hints na revisão de P0

Resultado	Avaliações
Full body preferido	12
Hints preferidas	3
Ambos equivalentes	3
Nenhum aceitável	0

Fonte: run `ca713efe-e7ee-4023-b77c-6301251914c0` (2026).

O contraste não prova que toda compressão seja prejudicial, mas mostra que a extração usada perdeu instruções capazes de alterar objetivos e critérios verificáveis. Esse resultado motivou a remoção de `SkillHint` do caminho normativo de P1.

O segundo laboratório separou dois fatores: gerar o plano final diretamente ou revisar um P0; e recuperar skills pela requisição inteira ou por cada objetivo de P0. Dois runs completos, cada um com 18 avaliações e dois juízes, produziram:

Quadro 9 - Comparações fatoriais de planejamento

Comparação	Esquerda	Direita	Ambos	Inconsistente
Direct × Request P1	15	44	0	13
Direct × Direct Goal	30	27	0	15
Request P1 × Goal P1	18	39	5	10
Direct Goal × Goal P1	18	43	0	11
Direct × Goal P1	20	44	0	8

Fonte: runs 88a74c54-fa6e-456b-b6ae-b963205667fd e
aaaa645e-a9b2-4d2c-a3bd-119f13cc7879 (2026).

Quando a evidência de retrieval é mantida constante, as duas comparações favorecem P1: Request P1 supera Direct por 44–15 e Goal P1 supera Direct Goal por 43–18. A comparação entre as duas políticas diretas fica próxima, 30–27. A evidência indica que a ancoragem em um P0 independente do catálogo e sua revisão posterior são o fator dominante; retrieval por objetivo parece útil principalmente em interação com esse P0.

9.3 Retrieval de alta cobertura não é seleção final

Nos 36 resultados dos dois runs fatoriais havia 132 ocorrências de skills esperadas. Com threshold de reranker 0,30, a união por objetivo recuperou todas as 132, mas entregou 233 ocorrências ao planner. A recomputação sobre os traces persistidos mostra o trade-off:

Quadro 10 - Sweep diagnóstico do threshold de reranking

Threshold	Selecionadas	Hits esperados	Precisão proxy	Recall esperado
0,300	233	132	56,7%	100,0%
0,325	199	129	64,8%	97,7%
0,350	157	124	79,0%	93,9%
0,375	135	115	85,2%	87,1%
0,400	126	111	88,1%	84,1%

Fonte: traces persistidos dos runs fatoriais (2026).

Elevar o threshold remove contexto, mas perde rapidamente skills esperadas. O reranker funciona como gerador de candidatas de alta cobertura; seu score isolado não representa utilidade marginal para P1. Essa observação fundamenta a separação entre reranking e gate semântico.

9.4 Filtragem semântica do contexto de planejamento

O terceiro laboratório compara Full Goal P1, que recebe toda a união recuperada, com Gated Goal P1, que recebe somente os bodies mantidos por um gate global. Os braços compartilham

P0, retrieval, reranking, candidatas, modelo, effort e prompt de revisão. O gate v1 era agressivo; v2 tornou a política conservadora; v3 reduziu o schema a keep ou drop.

Quadro 11 - Redução e retenção do gate

Gate	Candidatas	Mantidas	Redução	Recall condicional esperado	Precisão proxy
v1	121	50	58,7%	43/65 (66,2%)	43/50 (86,0%)
conservative-v2	123	64	48,0%	55/66 (83,3%)	55/64 (85,9%)
conservative-v3	123	68	44,7%	51/65 (78,5%)	51/68 (75,0%)

Fonte: runs de gate identificados abaixo (2026). A precisão é apenas uma proxy porque o conjunto esperado é incompleto.

Quadro 12 - Preferência cega entre contexto filtrado e integral

Gate	Gated P1	Full P1	Ambos	Inconsistente
v1	19	9	2	6
conservative-v2	20	8	6	2
conservative-v3	17	8	6	5

Fonte: 0c6eff6c-5071-49c1-aded-80d1466231aa,
f07edd93-a5a2-49cf-ba35-df9dfcd3932de
2acb1e81-791f-4afe-b68a-ac2fe1f2d773.

Os três runs repetem o mesmo efeito direcional: menos contexto não reduz a qualidade agregada e frequentemente a melhora. Ao mesmo tempo, v1 reteve somente 66,2% das skills esperadas que chegaram ao gate, e Spring Boot favoreceu o contexto integral nos runs conservadores. O gate é, portanto, útil e imperfeito. A política normativa favorece recall, exige alta confiança para drop e preserva orientação operacional, comportamento e verificação quando forem materialmente aplicáveis.

V2 e v3 não congelaram P0 e retrieval entre si; diferenças numéricas entre versões não podem ser atribuídas causalmente ao schema binário. V3 mostra apenas que keep/drop é suficiente para reproduzir a direção do efeito sem categorias adicionais.

9.5 Auditoria exaustiva do retrieval híbrido e do gate

A auditoria de 30 casos complementa a proxy incompleta dos experimentos anteriores com rótulos exaustivos sobre o catálogo. Para cada objetivo de P0, a consulta combina pedido e objetivo. Um índice BM25 sobre nome e body completos e um índice vetorial executam retrieval em paralelo. Candidatas vetoriais abaixo de 0,30 são removidas; as duas listas, limitadas a 20 itens, são fundidas por reciprocal rank fusion de pesos iguais; e um reranker body-aware escolhe até dez candidatas por objetivo. O gate avalia cada par objetivo-skill como keep ou drop; a união final mantém uma skill quando ao menos um objetivo a aprova.

Agregadas por caso, 389 ocorrências de skills chegaram ao gate: 79 relevantes e 310 de ruído. O bundle final conteve 88 ocorrências: as 65 esperadas, 13 suplementares úteis e dez de ruído. O resultado é resumido no Quadro 13.

Quadro 13 - Auditoria exaustiva de retrieval e seleção em 30 casos

Métrica	Contagem	Taxa
Recall das skills esperadas	65/65	100,0%
Precisão do bundle final	78/88	88,6%
F1 de precisão e recall esperado	—	94,0%
Retenção de itens relevantes recuperados	78/79	98,7%
Remoção de ruído recuperado	300/310	96,8%
Redução do conjunto recuperado	301/389	77,4%
Selection F1	—	93,4%

Fonte: run 89ba6c1e-470c-43ea-809b-a34a90f59540, 30 ago. 2026. Contagens são ocorrências agregadas por caso; relevante significa *expected* ou *useful*.

Vinte dos 30 casos tiveram precisão e retenção relevantes perfeitas. Nove casos mantiveram algum ruído; entre os dez falsos positivos, oito foram classificados como sem valor operacional e dois como irrelevantes. Nenhuma das seis ocorrências conflitantes recuperadas chegou ao bundle. O único falso negativo foi uma skill suplementar útil no caso de associação de fases sísmicas; nenhuma skill obrigatória foi perdida. O perfil residual sugere que a fronteira mais difícil não é reconhecer conflito explícito, mas decidir quando uma orientação tematicamente aplicável acrescenta valor operacional suficiente.

O run usou `qwen/qwen3.8-27b` com effort alto para P0, gate e P1, `voyageai/voyage-4-large` com 1.024 dimensões para embeddings e `voyageai/rerank-2.5` para reranking. As 2.581 chamadas bem-sucedidas reportaram uso e custo, totalizando 14.123.842 tokens contabilizados pelo provedor e 4,77550605 créditos. O manifest persistido registra os hashes das fontes do experimento, dos 30 casos e do catálogo de 37 skills. P1 foi gerado para preservar o trace completo, mas não foi julgado; essas métricas validam seleção, não qualidade downstream.

Um erro revela a interação mais importante para a próxima fase. No caso de viagem com orçamento, P0 transformou a necessidade de controlar custos em um *budget worksheet*, embora o pedido não exigisse uma planilha. Essa formulação tornou a skill `xlsx` aparentemente aplicável; o gate a manteve e P1 ampliou o requisito para fórmulas e subtotais. Retrieval lexical não criou sozinho esse erro, mas pode reforçar termos introduzidos pelo draft. O caso sustenta a regra da Seção 4.5: P0 deve chegar a P1 como rascunho falível, e uma skill não pode legitimar um entregável sem suporte no pedido.

Por fim, a topologia experimental não é idêntica ao gate global normativo. A auditoria decide por par objetivo-skill e faz união por nome; Γ , na especificação, recebe a união canônica e

o P0 completo e avalia cada candidata uma vez. O run sustenta retrieval híbrido, reranking body-aware e filtragem semântica pós-retrieval, mas não compara causalmente essas duas topologias de gate.

9.6 O que a evidência sustenta

Os experimentos sustentam quatro decisões encadeadas: P0 antes do catálogo; revisão em vez de geração final direta; preservação de full bodies; e filtragem semântica depois de retrieval de alta cobertura. A auditoria exaustiva acrescenta evidência direta de que a combinação lexical e vetorial recupera o conjunto obrigatório e de que o gate remove a maior parte do ruído sem sacrificar esse recall. Mais importante, os laboratórios fatoriais e de gate exercitam a interação entre essas partes, e não apenas cada componente isoladamente. Isso reduz a incerteza antes de uma campanha completa.

Ainda assim, desempenho local não é uma prova transitiva de desempenho total. A validação imediatamente seguinte deve congelar pedido, P0, candidatas recuperadas, modelo, effort e contrato de saída e comparar P1 com todos os bodies recuperados contra P1 com o bundle filtrado. Um baseline adicional sem skills mede o ganho sobre P0; um braço *pedido + mesmas skills*, sem mostrar o texto de P0 na síntese, isola o efeito de expor o draft. Como as candidatas desse último braço ainda foram recuperadas a partir dos objetivos de P0, ele não representa um pipeline integralmente independente de P0.

Essa próxima validação deve medir cobertura dos requisitos, contribuições realmente derivadas das skills, regressões, entregáveis não sustentados, verificabilidade e custo. Somente depois dela cabe atribuir ao gate melhora causal de P1. Routing final, menu de tools, execução, projeção de estado e revisão localizada permanecem para uma campanha end-to-end posterior com tarefas completas, tools reais e verificadores externos.

10 DISCUSSÃO E LIMITAÇÕES

10.1 Validação parcial, não end-to-end

O artigo demonstra preferências diagnósticas para mecanismos de planejamento e valida retrieval e seleção contra rótulos autorados exaustivos. Ele ainda não demonstra que o bundle filtrado produz P1 melhor do que o contexto integral, que bundles finais superam top-1, que a fórmula de tools aumenta sucesso, que a revisão localizada recupera execuções ou que o MOSAIC completo supera um agente direto. Essas claims exigem comparações pareadas com o mesmo modelo, as mesmas skills, tools, tarefas e verificadores. A Seção 9 deve ser lida como evidência de desenho e preparação para esses testes, não como seu substituto.

10.2 Dependência do modelo

Planner, reranker, seletor e executor dependem da capacidade do modelo de seguir instruções e distinguir comportamentos próximos. Um modelo fraco pode produzir objetivos inadequados, incluir skills redundantes ou ignorar partes do bundle. O MOSAIC organiza o problema, mas não elimina a dependência da competência do modelo.

10.3 Qualidade e tamanho dos bodies

Retrieval e execução dependem da qualidade do `SKILL.mcd`. Um body vago produz sinal vago. Como o núcleo carrega bodies completos, skills excessivamente longas aumentam custo e podem diluir atenção. A resposta mínima é disciplinar a autoria e manter $K_{\max}$ pequeno. Compressão automática e carregamento seletivo são extensões, não componentes centrais.

10.4 Gate, conflitos e ordem

O gate e o seletor evitam conflitos de forma qualitativa, e o bundle preserva a ordem do reranking com desempate determinístico. Na auditoria exaustiva, nenhum item conflitante foi selecionado, mas dez itens sem utilidade suficiente permaneceram e uma contribuição suplementar útil foi removida. Falsos keeps e falsos drops, portanto, continuam possíveis, especialmente em tarefas técnicas com várias orientações complementares. A regra conservadora reduz, mas não elimina, esse risco. A ordem de aplicabilidade também não é necessariamente ótima quando instruções possuem tensão implícita. Uma linguagem formal de precedência pode ser necessária em catálogos maiores, porém pertence a um perfil posterior se evidência empírica justificar o custo.

10.5 Ancoragem e propagação de erros de P0

Transportar P0 para P1 preserva cobertura e estrutura, e as comparações fatoriais desta versão favoreceram revisão sobre geração direta. Esse ganho não torna P0 correto por definição. Um objetivo inventado pode orientar retrieval, tornar um body aparentemente aplicável e voltar a P1 como requisito reforçado. Busca lexical aumenta a sensibilidade à formulação exata; retrieval vetorial pode reproduzir o mesmo efeito por proximidade semântica. O contrato da Seção 4.5 reduz esse risco ao tornar o pedido a autoridade de escopo e P0 um rascunho livremente revisável. Ele não elimina ancoragem cognitiva, que deve ser medida pelo braço sem exposição textual a P0 descrito na Seção 9.6.

10.6 Menu simples de tools

Tbase pode expor tools que o objetivo não usa. No perfil YOLO máximo, todas as tools ficam visíveis. Essa escolha prioriza simplicidade conceitual e resolve o caso de bundle vazio com

tool. Filtragem por estado, custo, causalidade ou risco pertence a arquiteturas de menu mais sofisticadas.

10.7 Subconjunto de Agent Skills

O perfil não executa scripts nem carrega referências e assets. Skills que dependem desses recursos não são integralmente executáveis pelo núcleo. Essa restrição é explícita e evita que o artigo prometa uma camada de resolução que não participa da ideia central.

10.8 Revisão localizada

O pedido de revisão pressupõe que o executor reconheça quando uma evidência altera o plano, e que o planner preserve resultados concluídos. Capturar automaticamente todas as observações elimina a autoria do ledger pelo modelo, mas a seleção de `observationIds` continua sendo semântica: o runtime verifica identidade, unicidade e disponibilidade causal no grafo ativo, não se o subconjunto citado é de fato suficiente. O perfil reduz esse risco com critérios explícitos e projeção causal compacta, sem introduzir verificador separado, reabertura automática de ancestrais ou replanejamento global.

10.9 Contratos mínimos não substituem operação de produção

Os contratos do perfil resolvem ambiguidade entre implementações, mas não especificam persistência distribuída, consistência transacional, retries de infraestrutura, idempotência, observabilidade com-pleta ou recuperação de infraestrutura. A validação local e a recuperação limitada de saídas estruturadas pertencem à correção semântica do runtime e não devem ser confundidas com essas políticas operacionais. Os contratos definem o que deve ser trocado entre os componentes, não como cada componente deve ser operacionalizado.

11 CONSIDERAÇÕES FINAIS

A MOSAIC 0.3 parte de uma distinção simples: objetivos descrevem resultados; skills ensinam comportamentos; tools executam operações; o modelo toma decisões semânticas; e o runtime detém a evidência operacional. O planner produz P0 sem nomes de skills. Retrieval por objetivo, lexical, vetorial ou híbrido, e reranking body-aware formam uma união de alta cobertura; um gate semântico conservador remove apenas candidatas sem utilidade material e P1 recebe os bodies canônicos mantidos. P0 permanece no contexto como rascunho falível, subordinado ao pedido original. O roteamento final então seleciona, independentemente para cada objetivo pronto, um bundle ordenado de zero a várias instruções e monta um menu composto por T_{base} e pelas tools declaradas nesse bundle.

A revisão 0.3 preserva os contratos de catálogo, plano, estado, bundle, contexto, decisão semântica, observação e resultado do nó definidos na 0.2. Sua mudança normativa é menor e baseada em evidência: remove `SkillHint` do caminho de planejamento, introduz um `PlanningGate` auditável e mantém independentes a seleção pré-P1 e o bundle de execução. Julgamentos pareados favoreceram full bodies, revisão P0–P1 e contexto filtrado; a auditoria exaustiva recuperou todas as 65 skills esperadas e removeu 96,8% do ruído recuperado. A próxima hipótese é downstream: demonstrar, com P0 e retrieval congelados, que o bundle filtrado produz P1 melhor do que o contexto integral. Somente uma campanha posterior de execução medirá a arquitetura completa e seu custo.

Não há compilador semântico obrigatório, tool router independente, camada de providers, resolvidor de recursos, solver formal de bundles, verificador separado, reabertura automática de nós concluídos ou protocolo operacional completo. A especificação assume execução YOLO e explicita seus limites. Com essa redução, a tese arquitetural pode ser enunciada de forma direta:

A granularidade do plano deve seguir resultados intermediários; a granularidade das instruções e das operações deve permanecer composicional dentro de cada objetivo. Quando o catálogo informa o planejamento, o runtime deve selecionar os bodies úteis, não comprimir antecipadamente as instruções que pretende aplicar.

REFERÊNCIAS

AGENT SKILLS. **Specification**. [S. l.], 2026. Disponível em: agentskills.io/specification. Acesso em: 29 jul. 2026.

AMIRAZ, Chen et al. The distracting effect: understanding irrelevant passages in RAG. In: ANNUAL MEETING OF THE ASSOCIATION FOR COMPUTATIONAL LINGUISTICS, 63., 2025. **Proceedings [...]** [S. l.]: ACL, 2025. p. 18228–18258. DOI: 10.18653/v1/2025.acl-long.892.

BABU, Rahul Suresh; IYER, Laxmipriya Ganesh. ToolMenuBench: benchmarking tool-menu filtering strategies for reliable and efficient LLM agents. **arXiv**, 2026. DOI: 10.48550/arXiv.2606.15508.

CHO, Hongcheol; KANG, Ryangkyung; KIM, Youngeun. SkillRet: a large-scale benchmark for skill retrieval in LLM agents. **arXiv**, 2026. DOI: 10.48550/arXiv.2605.05726.

CUCONASU, Florin et al. The power of noise: redefining retrieval for RAG systems. In: INTERNATIONAL ACM SIGIR CONFERENCE ON RESEARCH AND DEVELOPMENT IN INFORMATION RETRIEVAL, 47., 2024. **Proceedings [...]** New York: ACM, 2024. p. 719–729. DOI: 10.1145/3626772.3657834.

GAO, Xueping. Compositional skill routing for LLM agents: decompose, retrieve, and compose. **arXiv**, 2026. DOI: 10.48550/arXiv.2606.18051.

GONG, Jingzhi et al. SkillMOO: multi-objective optimization of agent skills for software

engineering. **arXiv**, 2026. DOI: 10.48550/arXiv.2604.09297.

HUANG, Jie et al. Large language models cannot self-correct reasoning yet. In: INTERNATIONAL CONFERENCE ON LEARNING REPRESENTATIONS, 2024. **Proceedings [...]** [S. l.]: ICLR, 2024. DOI: 10.48550/arXiv.2310.01798.

KIM, Kiseung; LEE, Jay-Yoon. RE-RAG: improving open-domain QA performance and interpretability with relevance estimator in retrieval-augmented generation. In: CONFERENCE ON EMPIRICAL METHODS IN NATURAL LANGUAGE PROCESSING, 2024. **Proceedings [...]** [S. l.]: ACL, 2024. p. 22149–22161. DOI: 10.18653/v1/2024.emnlp-main.1236.

LI, Xiangyi et al. SkillsBench: benchmarking how well agent skills work across diverse tasks. **arXiv**, 2026. DOI: 10.48550/arXiv.2602.12670.

MADAAN, Aman et al. Self-Refine: iterative refinement with self-feedback. In: ADVANCES IN NEURAL INFORMATION PROCESSING SYSTEMS, 36., 2023. **Proceedings [...]** [S. l.]: Curran Associates, 2023. DOI: 10.52202/075280-2019.

NING, Jingjie; LI, Xueqi; YU, Chengyu. Revision or re-solving? Decomposing second-pass gains in multi-LLM pipelines. **arXiv**, 2026. DOI: 10.48550/arXiv.2604.01029.

RU, Dongyu et al. RAGChecker: a fine-grained framework for diagnosing retrieval-augmented generation. In: ADVANCES IN NEURAL INFORMATION PROCESSING SYSTEMS, 37., 2024. **Proceedings [...]** [S. l.]: Curran Associates, 2024. p. 21999–22027. DOI: 10.52202/079017-0692.

SCHICK, Timo et al. Toolformer: language models can teach themselves to use tools. In: ADVANCES IN NEURAL INFORMATION PROCESSING SYSTEMS, 36., 2023. **Proceedings [...]** [S. l.]: Curran Associates, 2023. Disponível em: <https://arxiv.org/abs/2302.04761>. Acesso em: 29 jul. 2026.

WANG, Zihao et al. Describe, explain, plan and select: interactive planning with LLMs enables open-world multi-task agents. In: ADVANCES IN NEURAL INFORMATION PROCESSING SYSTEMS, 36., 2023. **Proceedings [...]** [S. l.]: Curran Associates, 2023. DOI: 10.52202/075280-1480.

YAO, Shunyu et al. ReAct: synergizing reasoning and acting in language models. In: INTERNATIONAL CONFERENCE ON LEARNING REPRESENTATIONS, 2023. **Proceedings [...]** [S. l.]: ICLR, 2023. DOI: 10.48550/arXiv.2210.03629.

ZHENG, YanZhao et al. SkillRouter: retrieve-and-rerank skill selection for LLM agents at scale. **arXiv**, 2026. DOI: 10.48550/arXiv.2603.22455.

APÊNDICE A - CONTRATOS NORMATIVOS

Este apêndice define a informação mínima que deve atravessar as fronteiras do runtime. Os Quadros A.1 e A.2 distinguem objetos de catálogo, planejamento, decisão do modelo e evidência criada pelo runtime. Em `Plan`, `revision` é um inteiro seguro não negativo materializado exclusivamente pelo runtime: P0 usa 0, P1 usa 1 e cada revisão localizada incrementa o valor

em uma unidade. O histórico de planos deve ser contíguo. O schema escrito pelo modelo contém apenas os campos semânticos dos nós e não permite que o modelo escolha a revisão.

O contrato normativo de artefato é a união discriminada abaixo. MIME type e referência são strings normalizadas não vazias; data pode ser vazio. Objetos sem kind, variantes híbridas e campos desconhecidos são inválidos.

```
Artifact =
  { kind: "inline", mime: string, data: string }
  | { kind: "reference", mime: string, reference: string }
```

NodeOutcome, estado projetado e FinalDelivery preservam a ordem desses artefatos. Referências são opacas; este contrato não introduz store, resolução, persistência, checagem de existência nem política de autorização.

Quadro A.1 - Contratos de catálogo, plano e routing

Objeto	Campos mínimos	Invariantes
SkillRecord	name, description, body, allowedTools[], indexText	nome único; body não vazio; todas as tools resolvem no registro
ToolDescriptor	name, inputSchema, outputSchema	nome único; schemas disponíveis ao executor
GoalNode	id, goal, doneWhen[], dependsOn[], status, deliver	ID único; dependências válidas; status permitido; decisões acopladas permanecem juntas; toda afirmação semântica aparece em doneWhen
Plan	nodes[], revision	DAG acíclico; revisão inteira não negativa, contígua e atribuída pelo runtime; ao menos um nó entregável; nós concluídos imutáveis em revisões
PlanningGate	evaluations[], selectionRationale; cada avaliação contém skillName, decision, rationale	cada candidata única é avaliada exatamente uma vez; decisão é keep ou drop; nomes resolvem no catálogo; rationales não substituem bodies
SkillCandidate	skillName, score, rank, rationale	aponta para skill canônica; rank total e determinístico após desempate
OrderedBundle	goalId, skills[], selectionRationale	cardinalidade de zero a $K_{\max}$; sem duplicatas; ordem final observável

Fonte: elaboração própria (2026).

Quadro A.2 - Contratos de execução, evidência e revisão

Objeto	Autoria e campos mínimos	Invariantes
NodeContext	runtime: pedido, objetivo, doneWhen, estado projetado, skills e tools	ancestrais concluídos; critérios, contagens e somente observações citadas; sem callId; bodies delimitados; menu igual a $T(g)$
NodeDecision	modelo: status, critérios com criterionIndex, satisfação, evidência em prosa e observationIds[], resultado, pedido de revisão e razão	IDs opacos, não vazios, únicos por critério e causalmente disponíveis; não contém observações nem callId
Observation	runtime: id, goalId, toolName, callId, entrada, saída e ordem	UUID opaco único no grafo ativo; chamada e retorno correlacionados exatamente uma vez; callId não serve como referência; a tool terminal de saída estruturada não é observação
NodeOutcome	runtime: os campos validados de NodeDecision; observações pertencem ao Node	referências são resolvidas contra o ledger local e a projeção causal do grafo ativo; referências inválidas rejeitam o outcome antes de qualquer promoção
RevisionRequest	modelo: goalId, invalidatedAssumption, requestedEffect	needs_revision exige pelo menos uma observação; o runtime associa automaticamente o conjunto completo produzido pelo nó
Artifact	runtime/modelo: kind, mime e data ou reference	união estrita entre conteúdo inline e referência opaca; ordem preservada; resolução e persistência fora do núcleo
FinalDelivery	runtime: objetivos terminais, partes e artefatos discriminados	construída sem nova chamada ao modelo; ordem estável e rastreável

Fonte: elaboração própria (2026).

A.1 Validações normativas

Antes da execução, o runtime deve verificar:

1. unicidade de nomes de skills e tools; 2. resolução de cada item de allowed-tools; 3. unicidade de IDs de objetivos; 4. existência de todas as dependências;
5. aciclicidade do plano; 6. $T_{\text{base}} \subseteq T_{\text{registry}}$; 7. $0 \leq |B(g)| \leq K_{\text{max}}$; 8. existência de pelo menos um resultado terminal entregável; 9. cobertura explícita em doneWhen de toda afirmação semântica relevante do objetivo; 10. cobertura exata da união C_0 pelas avaliações keep/drop do PlanningGate; 11. resolução canônica e ordem dos bodies mantidos em P1; 12. unicidade dos IDs por critério e disponibilidade causal de cada observação citada no grafo ativo.

A.2 Semântica de revisão do nó atual

Quando um nó running produz needs_revision, o próprio nó deve conter ao menos uma observação. O runtime entrega ao planner ID de observação, nome de tool, entrada e saída do ledger completo, preservando a ordem e omitindo callId. O planner pode manter o nó, substituí-lo ou inserir predecessores. Se o nó for mantido, seu ID permanece, seu status retorna a pending e seu novo ledger começa vazio; se for substituído, o ID antigo não pode ser reutilizado. Snapshots anteriores e nós concluídos preservam suas observações, mas evidências aposentadas não podem ser citadas no grafo ativo. Nenhum resultado parcial é promovido.

APÊNDICE B - CHECKLIST MOSAIC 0.3

Quadro B.1 - Requisitos de conformidade da MOSAIC 0.3

ID	Requisito	Obrigatório
C01	O planner inicial recebe o pedido sem nomes de skills.	Sim
C02	Cada nó possui resultado observável, <code>doneWhen</code> semanticamente completo e participa de um DAG válido; decisões acopladas permanecem juntas.	Sim
C03	O feedback do catálogo ocorre somente após P0 e no máximo uma vez antes da execução.	Sim
C04	O gate de planejamento lê o body completo e avalia cada candidata única exatamente uma vez com <code>keep</code> ou <code>drop</code> .	Sim
C05	P1 recebe somente os bodies canônicos mantidos; rationales não viram hints, e o roteamento final permanece independente.	Sim
C06	O reranking de execução lê o body canônico das candidatas.	Sim
C07	O bundle admite cardinalidade de zero a $K_{\max}$ e ordem determinística.	Sim
C08	O menu é $T_{\text{base}} \cup \bigcup A(s)$ para as skills selecionadas.	Sim
C09	A decisão do modelo contém somente campos semânticos e avaliações ordenadas cujos IDs de observação são opacos, não vazios e únicos por critério.	Sim
C10	O runtime captura automaticamente cada retorno serializável de tool executável com UUID opaco, na ordem dos resultados.	Sim
C11	IDs de observação vazios ou colidentes e resultados não serializáveis causam falha de runtime sem registro parcial.	Sim
C12	A tool terminal de saída estruturada nunca é registrada como observação.	Sim
C13	<code>needs_revision</code> exige ao menos uma observação e associa o pedido ao conjunto completo do nó.	Sim
C14	O planner localizado recebe ID, nome, entrada e saída de todas as observações, sem <code>callId</code> .	Sim
C15	Revisões preservam nós concluídos e seus resultados.	Sim
C16	A resposta final é empacotada sem nova chamada cognitiva.	Sim
C17	Nenhum objeto estruturado escrito pelo modelo altera plano ou estado antes de satisfazer o contrato completo do runtime.	Sim
C18	Cada ID citado resolve no ledger local ou na projeção causal do grafo ativo antes de outcome ou artefato ser promovido.	Sim
C19	Descendentes recebem somente critérios, observações citadas deduplicadas e artefatos de ancestrais concluídos, sem <code>callId</code> .	Sim
C20	<code>completed</code> revisa sinais de falha disponíveis; <code>blocked</code> exige impossibilidade concreta, alternativas tentadas e consideração de revisão.	Sim

Fonte: elaboração própria (2026).

Extensões podem coexistir com a MOSAIC 0.3 desde que não alterem silenciosamente esses contratos. Quando alterarem, a implementação deve declarar uma versão derivada em vez de usar o rótulo MOSAIC 0.3 sem qualificação.