

MOSAIC 0.2 — Protocolo auxiliar de validação empírica

Processo experimental para avaliar planejamento por objetivos, ativação de skills e composição de instruções

MOSAIC 0.2 — Auxiliary empirical validation protocol

João Vitor Scheuermann

MOSAIC 0.2 — 8 de agosto de 2026 / 8 August 2026

Documento auxiliar ao artigo técnico. Define testes de contrato, conformidade e avaliação empírica; não contém resultados experimentais.

RESUMO

Este documento descreve um protocolo para avaliar as hipóteses arquiteturais do MOSAIC (Micro-skill Orchestration through Skill Activation and Instruction Composition) e verificar a conformidade de implementações com o MOSAIC 0.2. Além de planejamento por objetivos, retrieval body-aware, bundles ordenados, menus de tools, revisão localizada e composição final única, o protocolo testa o contrato de evidência da execução. O modelo produz somente uma decisão semântica; o runtime correlaciona cada retorno de tool executável, cria registros *Observation* em ordem e materializa o resultado do nó. Uma revisão recebe automaticamente todas as observações do nó solicitante, sem depender de o modelo reproduzir identificadores do provedor. Toda saída estruturada escrita pelo modelo também deve satisfazer o contrato completo do runtime antes de alterar estado; tentativas inválidas, feedback limitado, correção ou esgotamento ficam observáveis no trace. A validação é separada em três níveis: testes de unidade e contrato, suíte determinística de conformidade e estudo empírico comparativo. O benchmark organiza seis classes de composição por objetivo focal, quatro domínios e atributos ortogonais de dificuldade e revisão. Cada caso admite múltiplos planos e bundles corretos e registra comportamentos obrigatórios, opcionais, proibidos e restrições de ordem. O protocolo usa baselines progressivos, ablações internas, oráculos diagnósticos, traces completos por estágio e verificadores determinísticos sempre que o resultado possui contrato observável. A métrica principal é o sucesso end-to-end por execução; métricas de planejamento, retrieval, bundle, menu, estado, evidência, revisão e custo explicam mecanismos e modos de falha. Segurança, prompt injection, autorização e sandbox permanecem fora do escopo, porque o artigo assume um runtime confiável em modo YOLO. O produto esperado é um pacote reproduzível contendo benchmark congelado, catálogo, prompts, configurações, traces, verificadores, testes de conformidade e relatório estatístico. **Palavras-chave:** avaliação de agentes; micro skills; planejamento; roteamento; evidência de execução; conformidade técnica.

ABSTRACT

This document specifies a protocol for evaluating the architectural hypotheses of MOSAIC (Micro-skill Orchestration through Skill Activation and Instruction Composition) and checking implementation conformance with MOSAIC 0.2. In addition to outcome-oriented planning, body-aware retrieval, ordered bundles, tool menus, localized revision, and single final assembly, it tests the execution-evidence contract. The model emits only a semantic decision; the runtime correlates every executable-tool result, creates ordered `Observation` records, and materializes the node outcome. A revision automatically receives every observation from its requesting node and never depends on the model reproducing provider identifiers. Every model-authored structured output must also satisfy the runtime’s complete contract before changing state; invalid attempts, limited feedback, correction, or budget exhaustion remain observable in the trace. Validation is separated into three levels: unit and contract tests, a deterministic conformance suite, and a comparative empirical study. The benchmark organizes six composition classes around a focus goal, four domains, and orthogonal difficulty and revision attributes. Each case allows multiple acceptable plans and bundles and records required, optional, and forbidden behaviors together with ordering constraints. The protocol uses progressive baselines, internal ablations, diagnostic oracles, complete stage-level traces, and deterministic verifiers whenever the output has an observable contract. End-to-end success per execution is the primary metric; planning, retrieval, bundle, menu, state, evidence, revision, and cost metrics explain mechanisms and failure modes. Security, prompt injection, authorization, and sandboxing remain out of scope because the paper assumes a trusted YOLO-mode runtime. The expected product is a reproducible package containing the frozen benchmark, catalog, prompts, configurations, traces, verifiers, conformance tests, and statistical report. **Keywords:** agent evaluation; micro-skills; planning; routing; execution evidence; technical conformance.

1 INTRODUÇÃO


1.1 Finalidade

O artigo principal apresenta uma arquitetura mínima. Este documento separa três questões: se a implementação respeita os contratos do perfil; se os mecanismos funcionam isoladamente; e se a combinação produz ganho end-to-end. O protocolo serve para orientar a construção de uma prova de conceito, uma suíte de conformidade, o benchmark, a execução das condições e o relatório dos resultados. Ele não substitui uma implementação e não antecipa conclusões. A unidade primária de evidência empírica é uma execução completa sobre um caso congelado. Cada execução deve deixar um trace suficiente para reconstruir o plano, as skills recuperadas, o bundle escolhido, o menu de tools, a projeção de estado, as chamadas, as observa-

ções criadas pelo runtime, a decisão semântica do modelo, o resultado materializado do

nó, as revisões, os status de nó e o resultado final. Métricas agregadas sem traces não permitem distinguir ganho arquitetural de um acerto fortuito do modelo.

Figura 1 – Cadeia de evidências do processo empírico



Fonte: elaboração própria (2026).

1.2 Relação com os trabalhos-base

O protocolo preserva os achados que motivam a arquitetura, mas testa cada mecanismo separadamente. SkillRouter informa a ablação metadata-only versus body-aware; SkillWeaver motiva a avaliação do feedback do catálogo sobre a decomposição; SkillsBench oferece o padrão de tarefas com verificadores e condições comparáveis; SkillRet orienta métricas de retrieval em catálogos maiores; SkillMOO reforça a necessidade de medir custo e redundância do bundle; ToolMenuBench sugere separar qualidade do menu e sucesso downstream (ZHENG et al., 2026; GAO, 2026; LI et al., 2026; CHO; KANG; KIM, 2026; GONG et al., 2026; BABU; IYER, 2026).

A validação do MOSAIC não precisa reproduzir integralmente esses benchmarks. O objetivo é usar desenhos compatíveis com a hipótese específica: uma tarefa é planejada por resultados, e cada objetivo pode ativar zero, uma ou várias micro skills sobre tools gerais ou específicas.

1.3 Escopo e não objetivos

O experimento assume o mesmo modelo de confiança do artigo: catálogo, runtime e tools são confiáveis; a execução ocorre em modo YOLO. Portanto, não são variáveis primárias: prompt injection, autorização, sandbox, credenciais, confirmação de efeitos, segurança de scripts ou políticas de least privilege. Esses temas podem ser avaliados por outro protocolo sem alterar as perguntas centrais desta validação. Também não se pretende provar que o MOSAIC é universalmente superior. O objetivo é estabelecer em que classes de tarefa cada mecanismo ajuda, não ajuda ou aumenta custo sem ganho. Um resultado negativo localizado é informativo: pode indicar que a composição só é necessária em tarefas com múltiplos comportamentos, ou que um mecanismo deve ser removido do núcleo.

Retries de transporte, backoff e recuperação de provider ou processo permanecem fora do núcleo e são tratados apenas pela regra pré-registrada de rerun técnico. Em contraste, rejeitar atômica uma saída estruturada que viola o contrato completo, fornecer feedback limitado e permitir correção dentro de um orçamento finito é comportamento semântico obrigatório do runtime e integra a suíte de conformidade.

1.4 Níveis de validação

A validação é organizada em três níveis com propósitos distintos:

1. **testes de unidade e contrato:** verificam parser, normalização, DAG, menus, projeção de estado e transições;
2. **suíte de conformidade MOSAIC:** verifica os invariantes do perfil em casos pequenos e determinísticos;
3. **estudo empírico comparativo:** mede mecanismos, sucesso, custo e variabilidade em tarefas abertas.

Falhar no primeiro ou no segundo nível invalida a execução principal, porque uma condição não conforme não representa a arquitetura que pretende avaliar.

2 REIVINDICAÇÕES, PERGUNTAS E HIPÓTESES

2.1 Reivindicações avaliáveis

Quadro 1 - Reivindicações que o experimento deve tornar observáveis

ID	Reivindicação	Predição observável
C1	Granularidade do plano	Planejar por resultados reduz nós que apenas espelham tools ou skills, sem esconder dependências necessárias.
C2	Retrieval body-aware	O conteúdo integral de SKILL.md melhora recuperação e reranking quando descrições são próximas ou incompletas.
C3	Bundles ordenados	Zero, uma ou várias skills por objetivo cobrem comportamentos complementares melhor que top-1 e top-k indiscriminado.
C4	Menu T_{base} + bundle	Tools gerais continuam disponíveis com bundle vazio, enquanto skills acrescentam tools ligadas a procedimentos especializados.
C5	Revisão localizada	Observações que invalidam uma suposição podem alterar apenas objetivos não concluídos e aumentar recuperação após desvio.
C6	Efeito end-to-end	A combinação dos mecanismos aumenta sucesso nas classes composicionais sem depender de uma tool cognitiva artificial.

Fonte: elaboração própria (2026).

2.2 Perguntas de pesquisa

• RQ1: O planner produz objetivos orientados a resultados com cobertura adequada, dependências corretas e menor sobredecomposição? • RQ2: O body completo aumenta recall e qualidade de ranking em relação a `name + description`? • RQ3: A seleção de bundle aumenta cobertura comportamental sem acumular skills redundantes ou conflitantes? • RQ4: A fórmula de menu permite tool geral com bundle vazio e evita exigir skills artificiais? • RQ5: A revisão localizada recupera execuções quando uma observação muda a estrutura da tarefa? • RQ6: O MOSAIC completo aumenta sucesso end-to-end nas tarefas que exigem composição, e a que custo?

2.3 Hipóteses pré-registradas

• H1: O planner orientado a resultados terá maior cobertura de resultados e menor taxa de nós mecânicos que a decomposição uma-skill-por-subtarefa. • H2: Body-aware retrieval terá Recall@K e nDCG@K superiores à condição metadata-only, sobretudo em pares de skills funcionalmente próximos. • H3: O bundle seletivo terá maior cobertura comportamental que top-1 e menor redundância que top-k indiscriminado. • H4: Casos de operação geral dependentes de estado externo terão sucesso com bundle vazio quando Tbase contém a tool necessária e perderão desempenho na ablação sem Tbase. • H5: Em casos com mudança estrutural, a revisão localizada elevará a taxa de recuperação sem alterar resultados de objetivos já concluídos. • H6: Nas classes composicionais, o MOSAIC completo terá maior sucesso end-to-end que o baseline não-MOSAIC pré-definido; em tarefas triviais, o ganho pode ser nulo. H4 não deve ser testada apenas com aritmética cujos

operandos aparecem no prompt, porque o modelo pode responder sem tool. Os casos devem ocultar uma informação necessária em fixture, arquivo, registro simulado ou outro estado externo verificável. As hipóteses devem ser registradas antes da execução no conjunto de teste. Mudanças motivadas pelo piloto são permitidas somente antes do congelamento final.

3 DESENHO DO BENCHMARK

3.1 Unidades de análise

Quadro 2 - Unidades registradas no benchmark

Unidade	Definição operacional
Caso	Pedido, ambiente inicial, catálogo disponível, objetivo focal e critérios de sucesso.
Objetivo	Resultado intermediário produzido pelo planner.
Candidata	Skill devolvida pelo primeiro estágio de retrieval.
Ranking	Ordem produzida pelo reranker para um objetivo.
Bundle	Sequência de skills ativadas para um objetivo.
Menu	Conjunto de tools visíveis durante a execução de um objetivo.
Trajetória	Sequência de decisões, chamadas, observações, status e revisões.
Execução	Uma repetição completa de uma condição sobre um caso; unidade da análise primária.
Caso agregado	Proporção de execuções bem-sucedidas entre as repetições da mesma condição no caso; estatística descritiva.

Fonte: elaboração própria (2026).

3.2 Classes de composição

Cada caso declara um `focus_goal_role`: o objetivo cuja estrutura isola o mecanismo principal do caso. A classe é atribuída a esse objetivo focal, não à tarefa inteira. Outros objetivos podem existir, mas não alteram o estrato. A necessidade de revisão é um atributo ortogonal, e não uma classe.

Quadro 3 - Classes de composição do objetivo focal

Classe	Nome	Estrutura esperada	Exemplo de propriedade
A	direto	bundle vazio; nenhuma tool necessária	transformação simples ou resposta já suportada pelo contexto
B	tool base	bundle vazio; uma ou mais tools de T_{base} causalmente necessárias	ler fixture conhecida, consultar registro opaco ou executar transformação exata
C	cognitivo	uma ou mais skills; nenhuma tool necessária	interpretação, comparação ou redação sobre dados disponíveis
D	uma skill + tools	exatamente uma skill; uma ou várias tools	descoberta e leitura de documento; persistência de artefato
E	várias skills, menu simples	duas ou mais skills; zero ou uma tool causalmente necessária	análise combinando método, evidência e incerteza sobre a mesma entrada
F	várias skills, várias tools	duas ou mais skills; duas ou mais tools causalmente necessárias	obter, analisar, comparar e produzir efeito externo

Fonte: elaboração própria (2026).

Cada objetivo também recebe a assinatura:

```
skill_count: 0 | 1 | many
tool_requirement: none | base | declared | mixed
tool_count: 0 | 1 | many
requires_revision: boolean
requires_external_effect: boolean
```

Essa assinatura permite análises mais precisas que o rótulo da classe e evita misturar composição, menu e adaptação.

3.3 Domínios

A configuração inicial recomendada usa quatro domínios, escolhidos por exigirem com-binações diferentes sem introduzir uma plataforma operacional grande:

- documentos e análise financeira: localizar, ler, interpretar e comparar evidências;
- engenharia de software: ler arquivos, seguir dependências, explicar ou propor mudanças;
- produção de artefatos: redigir conteúdo e persistir arquivo quando solicitado;
- comunicação e integrações: preparar mensagem, resolver destino e executar envio simu-lado.

Os mesmos conceitos devem aparecer em mais de um domínio. Por exemplo, `read` participa de documentos, código e contratos; `file-writing` pode persistir relatórios, README e configurações. Essa reutilização testa se a tool permanece geral enquanto o comportamento muda com a skill.

3.4 Dificuldade e adaptação

Quadro 4 - Níveis de dificuldade

Nível	Caracterização
D1 - explícita	O pedido nomeia o artefato, o resultado e o destino; poucos distratores.
D2 - implícita	O objetivo precisa inferir critérios ou resolver candidatos semelhantes.
D3 - adaptativa	Uma observação durante a execução invalida uma suposição do plano.

Fonte: elaboração própria (2026).

D3 normalmente implica `requires_revision=true`, mas o atributo permanece separado para permitir casos adaptativos que podem ser resolvidos dentro do mesmo nó sem replanejamento. A distribuição deve ser balanceada o suficiente para impedir que o resultado global seja dominado por tarefas diretas. O relatório sempre apresenta resultados por classe, domínio, dificuldade e revisão, além do agregado.

3.5 Tamanho inicial, piloto e conjunto de teste

A configuração inicial recomendada é um piloto com 60 casos e um benchmark principal com meta de 240 casos. A meta corresponde a 6 classes $\times$ 4 domínios $\times$ 10 casos. Os três níveis de dificuldade e o atributo de revisão são distribuídos dentro dessa matriz. Esse número é um ponto de partida de engenharia, não uma garantia de poder estatístico.

O piloto deve estimar variância, taxa-base e efeito provável. Com esses valores, realiza-se uma simulação de poder para definir o tamanho final necessário ao contraste primário. O tamanho é congelado antes da execução do teste; não deve ser aumentado ou reduzido em resposta ao sinal observado no conjunto final. Quando prompts ou regras forem ajustados, separe um conjunto de desenvolvimento. Uma divisão mínima é 20% para desenvolvimento e 80% para teste, estratificada por classe e domínio. Casos de teste e seus golds permanecem ocultos aos responsáveis pelo ajuste de prompts.

3.6 Catálogo de skills e registro de tools

A validação central pode usar um catálogo curado de 50 a 80 micro skills e 20 a 30 tools. O catálogo deve conter skills relevantes, skills parcialmente sobrepostas, equivalentes com procedimentos diferentes, distratores de mesmo domínio e skills incompatíveis com o objetivo. O body de cada skill deve ser completo o suficiente para sustentar sua seleção. Além dos arquivos canônicos, o catálogo experimental contém um mapa adjudicado:

```
skill_behavior_map: Record<SkillId, BehaviorId[]>
```

O mapa não é fornecido ao sistema. Ele serve para scoring e permite calcular cobertura, redundância, conflito e ordem sem enumerar todas as sequências possíveis de skills.

A escala do retrieval é uma variável separada. Depois de validar a composição no catálogo curado, uma etapa de estresse pode acrescentar centenas ou milhares de distratores públicos

sem mudar os casos ou os golds. Isso evita confundir falha do conceito com falha de um retriever subdimensionado. O registro de tools deve incluir operações gerais, como `list`, `read`, `write` e `calculator`, além de integrações simuladas. Tbase é fixado por condição. Todas as condições recebem os mesmos schemas e implementações; apenas o menu visível pode mudar.

3.7 Estrutura de um caso gold

Um caso não contém uma única cadeia correta. Ele contém conjuntos e restrições que descrevem soluções aceitáveis. A anotação mínima é:

```
case_id: string
request: string
domain: string
focus_goal_role: GoalRole
composition_class: A | B | C | D | E | F
difficulty: D1 | D2 | D3
requires_revision: boolean
tool_requirement: none | base | declared | mixed
acceptable_plans: PlanAlternative[]
required_behaviors: Record<GoalRole, BehaviorId[]>
optional_behaviors: Record<GoalRole, BehaviorId[]>
forbidden_behaviors: Record<GoalRole, BehaviorId[]>
ordering_constraints: PrecedenceConstraint[]
acceptable_bundles?: Record<GoalRole, SkillSequence[]>
required_tools: Record<GoalRole, string[]>
optional_tools: Record<GoalRole, string[]>
forbidden_mechanistic_splits: string[]
success_criteria: Criterion[]
revision_oracle?: RevisionExpectation
```

`GoalRole` é uma função semântica, como obter-documento, interpretar-resultados ou persistir-artefato. O matching não depende do identificador textual exato criado pelo planner. `acceptable_bundles` é opcional: pode registrar sequências frequentes, mas as métricas principais derivam dos comportamentos e das restrições de ordem.

4 CONDIÇÕES EXPERIMENTAIS E ABLAÇÕES

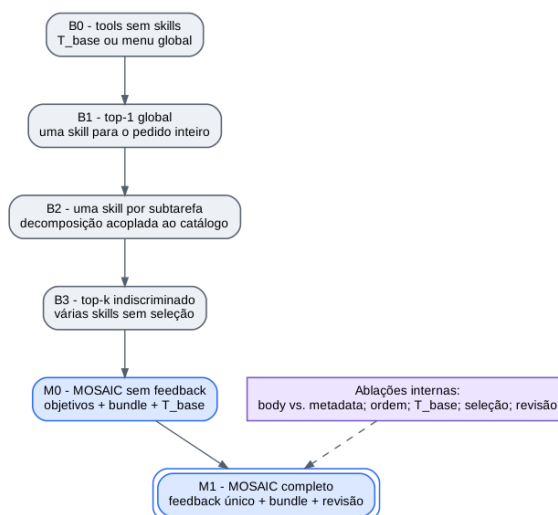
4.1 Baselines progressivos

Quadro 5 - Condições principais

ID	Condição	Diferença controlada
B0	Tools sem skills	Modelo recebe T_{base} ou menu global, sem bodies de skills.
B1	Top-1 global	Uma skill é escolhida para o pedido inteiro; não há bundle por objetivo.
B2	Uma skill por subarefa	Decomposição acoplada a uma skill por etapa, semelhante ao baseline composicional.
B3	Top-k indiscriminado	As k primeiras skills por objetivo são injetadas sem seletor de bundle.
M0	MOSAIC sem feedback	Plano por objetivos, retrieval body-aware, bundle ordenado, T_{base} e revisão localizada, mas sem $P_0 \rightarrow P_1$.
M1	MOSAIC completo	Inclui feedback único do catálogo e todos os demais mecanismos do perfil.

Fonte: elaboração própria (2026).

Figura 2 – Escada de condições e posição das ablações



Fonte: elaboração própria (2026).

Para tornar as diferenças auditáveis, cada condição deve preencher a matriz do Quadro 6.

Quadro 6 - Matriz normativa das condições

Propriedade	B0	B1	B2	B3	M0	M1	
Plano por objetivos	não exigido	não exigido	não	sim	sim	sim	
Skill por pedido inteiro	não	sim	não	não	não	não	
Routing por objetivo	não	não	por subtarefa	sim	sim	sim	
Reranking body-aware	não	configurável	configurável	sim	sim	sim	
Bundle $0..K_{\max}$	não	1 global	1 por etapa	top-k fixo	seletivo	seletivo	
Feedback $P_0 \rightarrow P_1$	não	não	não	não	não	sim	
Menu T_{base} + bundle	base/global	global	definido pela skill	sim	sim	sim	
Revisão localizada	não	não	não	opcional	sim	sim	

Fonte: elaboração própria (2026).

4.2 Ablações internas

Quadro 7 - Ablações para atribuir causalidade aos mecanismos

Ablação	Manipulação
A1 - metadata-only	Indexar e reranquear apenas <code>name + description</code> ; comparar com body completo.
A2 - ordem do bundle	Preservar a ordem determinística versus embaralhar as mesmas skills selecionadas.
A3 - sem T_{base}	Definir $T_{\text{base}} = \emptyset$ para isolar objetivos de classe B.
A4 - sem seleção	Substituir o bundle seletivo pelo top-k fixo.
A5 - sem revisão localizada	Ignorar <code>needs_plan_revision</code> e manter o plano estático.

Fonte: elaboração própria (2026).

M0 já é a ablação de feedback inicial; por isso não existe uma A6 duplicada. Não é necessário executar todas as ablações em todos os casos. A1 concentra-se em retrieval; A3 em classe B; A5 em casos com `requires_revision=true`; A2 e A4 em classes E e F.

4.3 Oráculos diagnósticos

Condições oracle não são baselines competitivos; são instrumentos de diagnóstico:

- `oracle-plan`: fornece ao restante do sistema um plano gold aceitável;
- `oracle-retrieval`: garante uma shortlist que cubra todos os comportamentos necessários;
- `oracle-bundle`: fornece um bundle aceitável, mantendo execução e tools;
- `oracle-menu`: fornece o menor menu que contém todas as tools necessárias;
- `oracle-state`: fornece resultados intermediários corretos para isolar execução posterior e entrega final.


A diferença entre o sistema completo e cada oracle estima o teto de melhoria de um estágio. Se `oracle-bundle` não melhora a execução, o gargalo não está na seleção de skills.

5 PROCESSO DE ANOTAÇÃO

5.1 Papéis e independência

Cada caso é anotado por duas pessoas de forma independente. Um terceiro papel adjudica divergências. Os anotadores recebem o pedido, o ambiente, o catálogo e os schemas das tools, mas não veem saídas dos sistemas que serão comparados. Esse isolamento evita construir o gold em torno dos erros ou escolhas de uma condição específica.

Figura 3 – Fluxo de anotação, concordância e adjudicação



Fonte: elaboração própria (2026).

5.2 Objeto de anotação

Os anotadores registram sete camadas:

1. resultados que precisam existir ao final da tarefa;
2. planos aceitáveis e dependências necessárias;
3. comportamentos obrigatórios, opcionais e proibidos por papel de objetivo;
4. restrições de precedência quando a ordem altera interpretação;
5. bundles aceitáveis por papel quando a enumeração é útil, inclusive sequência vazia;
6. tools necessárias, opcionais e operações que não devem virar nós próprios;
7. critérios verificáveis de sucesso e, quando aplicável, revisão esperada.

Uma skill é aceitável somente quando seu body acrescenta comportamento útil ao objetivo. Compartilhar palavras com o domínio não é suficiente. Uma tool é necessária quando o

caso não pode ser concluído sem sua operação, não apenas porque uma skill a declara.

5.3 Múltiplas respostas aceitáveis

Planos são comparados por papéis semânticos, não por igualdade textual. Duas de-composições podem ser aceitas se produzem os mesmos resultados intermediários, preservam dependências e não introduzem divisões mecânicas. Bundles também podem ter alternativas: uma skill mais abrangente pode substituir duas micro skills, desde que o body cubra os comportamentos anotados e respeite as restrições de ordem. A adjudicação deve registrar por que as alternativas são equivalentes. Essa justificativa passa a fazer parte do benchmark e permite auditoria futura quando o catálogo mudar.

5.4 Concordância e congelamento

Antes de congelar o benchmark, calcule concordância por camada: acordo categórico para classe, dificuldade e revisão; F1 de arestas para dependências; Jaccard ou F1 de conjuntos para comportamentos, skills e tools; e Krippendorff α para rubricas ordinais quando houver avaliação humana (KRIPPENDORFF, 2018). Como critério interno inicial, recomenda-se revisar o manual quando α categórico ficar abaixo de 0,80 ou a similaridade média dos comportamentos obrigatórios ficar abaixo de 0,70. Esses valores não são propriedades universais; são gatilhos de qualidade definidos antes da anotação completa. Após a adjudicação, o caso recebe versão, hash e estado `frozen`.

5.5 Controle de vazamento

- não usar casos de teste para ajustar prompts, Kretrieve, Khint, Kmax ou Tbase;
- não incluir no body da skill o texto literal dos pedidos de teste;
- manter famílias de casos e templates separados entre desenvolvimento e teste;
- registrar origem de skills públicas e remover duplicatas literais;
- congelar o catálogo e o `skill_behavior_map` antes da execução principal.

6 PROTOCOLO DE EXECUÇÃO

6.1 Congelamento de configuração

Cada condição precisa de uma ficha de configuração imutável durante a execução principal:

- identificador e versão do modelo;
- parâmetros de amostragem e seed quando suportada;
- prompts de planner, reranker, seletor, executor e compositor;
- hash do catálogo e dos `SKILL.md`;
- registro de tools, schemas e Tbase;
- Kretrieve, Khint, Kmax, Lnode, Rmax e orçamento de contexto;
- versão do código, ambiente e data de execução.

Mudanças após o início do teste criam uma nova condição e não substituem silenciosamente resultados anteriores.

6.2 Repetições, randomização e agregação


A configuração inicial usa cinco repetições independentes por caso e condição. O número pode ser revisto após o piloto se a variância entre execuções for muito baixa ou alta. A ordem de casos e condições deve ser randomizada, e execuções do mesmo caso não devem compartilhar estado ou cache de resposta do modelo.

A execução é a unidade da análise inferencial primária. O caso agregado é a proporção de repetições bem-sucedidas, usada para descrição e visualização; não se aplica regra de maioria para converter repetições em um único rótulo antes do modelo principal. Para modelos determinísticos, as repetições ainda podem variar a ordem de distratores ou a ordem controlada de candidatos nas ablações. O relatório distingue variabilidade do modelo, do catálogo e da ordem do prompt.

6.3 Trace obrigatório

O trace deve conservar entradas e saídas estruturadas de cada estágio, sem exigir cadeia privada de raciocínio. Basta registrar decisões observáveis: plano produzido, justificativas curtas, shortlist, scores, ordem, bundle, menu, projeção de estado, chamadas, retornos, decisão semântica do modelo, observações do runtime, resultado materializado do nó, revisões e resposta final.

Figura 4 - Trace mínimo e atribuição causal na MOSAIC 0.2



Fonte: elaboração própria (2026).

```

run_id: string
case_id: string
condition_id: string
repeat: number
configuration_hash: string
initial_plan: Plan
skill_hints?: SkillHint[]
revised_plan?: Plan
node_traces: NodeTrace[]
structured_output_attempts: StructuredOutputAttempt[]
final_delivery: FinalDelivery

verifier_results: CriterionResult[]
human_scores?: HumanScore[]
usage: {

input_tokens, output_tokens, model_calls, tool_calls,
latency_ms, cost
}

```

Cada NodeTrace deve conter:

```

goal_id: string
initial_status: NodeStatus
final_status: NodeStatus
routing_query: string
shortlist: Candidate[]
reranking: RankedCandidate[]
bundle: SkillId[]
menu: ToolId[]
state_view_refs: StateKey[]
model_calls: ModelCallRecord[]
tool_calls: ToolCallRecord[]
model_decision: NodeDecision
observations: Observation[]
materialized_outcome: NodeOutcome
revision_event?: PlanRevisionRecord

```

Cada tentativa estruturada em P0, P1, hint, seleção de bundle, decisão de nó ou revisão localizada deve produzir um registro observável:

```

stage: StructuredStage
scope_id: string
attempt: number

```

```
provider_accepted: boolean
runtime_accepted: boolean
feedback_sent: boolean
diagnostic?: string
state_hash_before: string
state_hash_after: string
```

Para uma submissão rejeitada, os hashes de estado devem permanecer iguais. O diagnóstico e o feedback registram somente informação limitada sobre a violação; o feedback enviado ao modelo não repete o payload rejeitado. O trace deve mostrar se uma tentativa posterior foi aceita ou se o orçamento finito terminou em falha. Essa instrumentação separa aceitação estrutural pelo provider de conformidade com invariantes locais não representáveis em JSON Schema.

`NodeDecision` contém apenas status, avaliações ordenadas dos critérios, resultado, pedido de revisão e razão. Para cada retorno bem-sucedido de tool executável, o runtime deve criar exatamente uma `Observation`, correlacionada à chamada e ordenada pela posição do retorno nas mensagens. A tool terminal de saída estruturada não é uma observação. `NodeOutcome` é materializado pelo runtime ao combinar a decisão com a sequência completa de observações.

O identificador de chamada pode existir no registro interno de correlação e em `Observation`, mas não é campo da decisão do modelo e não deve aparecer no prompt de revisão. Um trace com chamada sem retorno, identificador duplicado, retorno duplicado ou retorno não correlacionado é inválido e caracteriza falha de runtime. Uma decisão `needs_revision` exige ao menos uma observação; a fila de revisão associa automaticamente todas as observações do nó e as expõe ao planner como blocos com nome da tool, entrada e saída. O trace também deve permitir verificar a ordem determinística por wave e por retorno, que a composição final ocorreu uma única vez e que ela não invocou o modelo depois do resultado terminal.

6.4 Tratamento de execução incompleta

Timeout, limite de passos, saída inválida, status `blocked`, status `failed` ou tool indisponível são resultados, não casos a serem removidos. Uma saída estruturada semanticamente inválida deve seguir a recuperação limitada da própria condição; correção aceita ou esgotamento permanecem no mesmo trace e nunca autorizam rerun técnico. Um rerun técnico só é permitido quando a infraestrutura falhou fora do comportamento da condição, por exemplo processo interrompido antes de enviar a primeira requisição. A regra de rerun deve ser registrada antes do teste.

7 MÉTRICAS

7.1 Planejamento

Quadro 8 - Métricas do planner

Métrica	Definição
Cobertura de resultados	Proporção ponderada de papéis necessários representados por ao menos um objetivo aceitável.
Sobredecomposição	Nós sem resultado intermediário próprio, criados apenas para espelhar uma tool ou micro skill, divididos pelo total de nós.
Subdecomposição	Papéis que deveriam ser avaliados separadamente, mas foram fundidos de modo a ocultar dependência ou critério de conclusão.
Precisão/recall/F1 de arestas	Comparação entre dependências produzidas e qualquer alternativa gold compatível.
Aceitabilidade do plano	Indicador binário de pertencimento ao conjunto de planos aceitáveis após matching semântico auditável.
Tamanho do plano	Número de objetivos; métrica descritiva, não objetivo isolado de minimização.

Fonte: elaboração própria (2026).

7.2 Retrieval e reranking

- Recall@K: ao menos uma skill aceitável aparece na shortlist;
- coverage@K: proporção dos comportamentos gold coberta pela shortlist;
- MRR e Hit@1: posição da primeira skill aceitável;
- nDCG@K: qualidade da ordem quando há vários graus de relevância;
- delta body-aware: diferença entre body completo e metadata-only;
- taxa de confusão intrafamília: candidata do mesmo domínio, mas com procedimento inadequado, ranqueada acima da aceitável.

SkillRouter e SkillRet usam métricas de ranking e mostram que o problema permanece relevante em bibliotecas grandes; o protocolo adota essas métricas como diagnóstico, sem tratá-las como substituto do sucesso da tarefa (ZHENG et al., 2026; CHO; KANG; KIM, 2026).

7.3 Bundle

Quadro 9 - Métricas de composição

Métrica	Definição
Precisão de skills	Skills selecionadas que sustentam ao menos um comportamento aceitável para o objetivo.
Recall de comportamentos	Comportamentos obrigatórios cobertos pelo bundle produzido.
F1/Jaccard	Similaridade do conjunto com a melhor alternativa explícita, quando houver.
Exact acceptable bundle	Sequência produzida corresponde a uma alternativa explicitamente aceitável.
Cobertura comportamental	Proporção de comportamentos gold sustentada pelos bodies selecionados.
Redundância	Skills selecionadas sem comportamento adicional após considerar as anteriores.
Conflito	Bundles que contêm instruções incompatíveis para o mesmo objetivo.
Adequação da ordem	Proporção de precedências anotadas preservadas quando a ordem altera interpretação.
Tamanho e tokens	Número de skills e tokens de body injetados por objetivo.

Fonte: elaboração própria (2026).

7.4 Menu e uso de tools

Quadro 10 - Métricas do menu de tools

Métrica	Definição
Recall do menu	Tools necessárias presentes no menu do objetivo.
Precisão do menu	Tools visíveis que são necessárias ou opcionalmente aceitáveis; medida descritiva de overhead.
Tool incorreta	Chamada incompatível com o objetivo ou com o estado.
Tool visível não usada	Proporção de tools expostas que nunca são chamadas; medida descritiva.
Eficiência de chamadas	Chamadas necessárias ou úteis divididas pelo total.
Bundle vazio + T_{base}	Sucesso em objetivos de classe B.
Reuso	Mesma tool usada corretamente sob bundles de domínios diferentes.

Fonte: elaboração própria (2026).

Quando $T_{base} = T_{registry}$, baixa precisão do menu é esperada por construção e não constitui

medidos separadamente. Neste protocolo, risco de segurança não é métrica primária; contam-se tamanho, adequação, chamadas incorretas, passos e custo (BABU; IYER, 2026).

7.5 Estado e revisão localizada

- correção da projeção: entradas causais necessárias presentes e ramos irrelevantes ausentes;
- reutilização de estado: resultados intermediários necessários efetivamente consumidos;
- completude de captura: todo retorno bem-sucedido de tool executável gera uma observação, e a tool terminal não gera;
- correlação: chamadas e retornos são associados uma única vez, sem ausências ou duplicatas;
- ordem: observações seguem a ordem dos retornos e revisões concorrentes seguem a ordem determinística da wave;
- recall da revisão: revisões esperadas que foram acionadas;
- precisão da revisão: revisões acionadas que eram realmente necessárias;
- completude da evidência de revisão: o planner recebe todas as observações do nó, inclusive quando a evidência invalidante não é a primeira nem a última;
- isolamento de IDs: o prompt de revisão não contém identificadores de chamada;
- correção da revisão: o plano revisado pertence a uma alternativa aceitável;
- preservação: objetivos concluídos e seus resultados permanecem inalterados;
- recovery rate: casos fora de rota que terminam com sucesso após revisão;
- custo da revisão: chamadas, tokens e latência adicionais.

7.6 Métrica principal e eficiência

A métrica primária é sucesso end-to-end por caso e repetição. Uma execução é bem-sucedida quando todos os critérios obrigatórios são satisfeitos. Para artefatos e integrações simuladas, o verificador checa o estado observável; para análises abertas, combina-se rubrica humana cega com checks estruturais. Eficiência é reportada por tarefa e por sucesso: tokens de entrada e saída, chamadas de modelo, chamadas de tool, passos, latência e custo monetário estimado. O

MOSAIC não precisa ser sempre mais barato; o relatório deve mostrar se o ganho de qualidade exige custo desproporcional e em quais classes.

7.7 Mapa entre claims e métricas

Quadro 11 - Ligação entre reivindicações e evidências

Claim	Métricas primárias
C1	cobertura, sobre/subdecomposição, F1 de dependências
C2	Recall@K, nDCG@K, delta body-aware, confusão intrafamília
C3	cobertura comportamental, bundle F1, redundância, conflito, ordem, tokens
C4	recall do menu, classe B, reuso de tool; precisão como overhead
C5	trigger precision/recall, correção, preservação, recovery rate
C6	sucesso end-to-end, custo por sucesso e análise por estrato

Fonte: elaboração própria (2026).

8 VERIFICAÇÃO E AVALIAÇÃO HUMANA

8.1 Hierarquia de verificação

O protocolo usa a forma de verificação mais direta disponível, nesta ordem:

1. verificador determinístico do estado ou artefato; 2. check estruturado sobre JSON, arquivo ou registro de tool; 3. rubrica humana cega para qualidade semântica aberta; 4. LLM-as-judge apenas como medida auxiliar calibrada contra avaliações humanas.

SkillsBench demonstra a utilidade de tarefas com verificadores determinísticos e condições comparáveis. O MOSAIC deve adotar esse padrão sempre que o pedido termina em um estado observável, como arquivo criado, documento correto lido ou mensagem enviada em ambiente simulado (LI et al., 2026).

8.2 Rubrica para saídas abertas

Quadro 12 - Rubrica ordinal sugerida para análises e recomendações

Dimensão	Escala 0-2
Fidelidade	0: contradiz ou inventa; 1: parcialmente apoiado; 2: afirmações materiais apoiadas.
Cobertura	0: omite resultados centrais; 1: cobre parte; 2: cobre todos os critérios obrigatórios.
Decisão	0: sem critério; 1: critério implícito ou incompleto; 2: alternativas e critério explícitos.
Incerteza	0: certeza indevida; 1: limitação genérica; 2: premissas e dados ausentes específicos.
Concisão e formato	0: viola formato; 1: parcialmente adequado; 2: formato e extensão atendidos.

Fonte: elaboração própria (2026).

A ordem das respostas e a identidade da condição são ocultadas dos avaliadores. Casos

discordantes são avaliados por um terceiro julgador. O relatório apresenta acordo e distribuição por dimensão, não apenas uma média única.

8.3 Matching de planos e bundles

Matching semântico deve ser auditável. Primeiro, mapeiam-se objetivos produzidos aos papéis gold com base em resultado e `doneWhen`. Depois, avaliam-se dependências. Para bundles, verifica-se se o body de cada skill cobre os comportamentos atribuídos ao papel e se as precedências necessárias foram preservadas. Um modelo pode sugerir o matching, mas uma amostra estratificada deve ser revisada por humanos; todos os casos limítrofes entram na adjudicação.

9 ANÁLISE ESTATÍSTICA

9.1 Contrastes primários

O contraste principal compara M1 com o baseline não-MOSAIC previamente definido nas classes E e F e nos casos adaptativos relevantes. Contrastes secundários comparam mecanismos: M1 versus M0 para feedback; body-aware versus metadata-only; bundle seletivo versus top-k; revisão versus plano estático; Tbase versus ausência de Tbase em classe B. A escolha do baseline principal deve ser feita pelo conjunto de desenvolvimento ou por regra pré-registrada, não pelo resultado do teste. Alternativamente, compare M1 com todos os baselines e aplique correção de Holm (HOLM, 1979).

9.2 Modelo de análise

Análise principal usa cada execução como observação. Para sucesso binário, recomenda-se regressão logística de efeitos mistos, com condição, classe e sua interação como efeitos fixos e intercepto aleatório por caso. Quando houver mais de um modelo, modelo pode entrar como efeito fixo ou aleatório conforme o número de níveis e o plano pré-registrado.

A proporção de sucesso por caso é reportada descritivamente. McNemar é reservado a análises de sensibilidade com uma única execução determinística ou com um desfecho binário pré-agregado por regra registrada antes do teste (MCNEMAR, 1947). Uma alternativa não paramétrica é bootstrap por caso, preservando todas as repetições dentro do bloco. Para métricas contínuas assimétricas, como tokens ou redundância, use diferenças pareadas, intervalos bootstrap e, como teste simples, Wilcoxon (WILCOXON, 1945; EFRON; TIBSHIRANI, 1993). Reporte diferença absoluta, diferença relativa, tamanho de efeito e intervalo de 95%. P-valores isolados não substituem magnitude e incerteza.

9.3 Multiplicidade e hierarquia


Defina uma métrica primária e um contraste primário. Métricas de componente são explicativas. Dentro de cada família de hipóteses, aplique correção de Holm. Resultados exploratórios por domínio, skill individual, status de nó ou tipo de erro são rotulados como exploratórios e não usados para reescrever a hipótese principal.

9.4 Poder e regra de parada

A regra de parada é o número congelado após o piloto. O piloto estima a distribuição de efeitos e permite simular poder para o contraste primário. O conjunto final não é inspecionado para decidir quando parar. Casos podem ser excluídos apenas por critérios previamente definidos, como fixture corrompida ou gold comprovadamente inválido; toda exclusão é reportada com motivo.

10 FASES DO ESTUDO

Figura 5 - Fases recomendadas da validação



Fonte: elaboração própria (2026).

Quadro 13 - Entregas por fase

Fase	Entrega
0 - protocolo	Congelar claims, condições, métrica primária, reruns e análise.
1 - testes de contrato	Validar schemas, DAG, menus, captura automática, correlação e materialização de observações.
2 - conformidade MOSAIC 0.2	Executar casos determinísticos e corrigir desvios.
3 - piloto	Medir variância, ambiguidade e estimar o tamanho final.
4 - freeze	Congelar benchmark, golds, catálogo, prompts, configuração e plano estatístico.
5 - principal	Executar todas as condições e repetições sem tuning.
6 - análise	Aplicar scoring, estatística, ablações e atribuição causal.
7 - replicação	Repetir contrastes centrais com outro modelo, catálogo ou domínio.

Fonte: elaboração própria (2026).

11 TAXONOMIA DE ERROS E ATRIBUIÇÃO CAUSAL

11.1 Categorias

Quadro 14 - Taxonomia mínima de falhas

Código	Falha
P - planejamento	resultado ausente, nó mecanístico, dependência errada ou plano excessivo
R - retrieval	skill aceitável não aparece na shortlist
K - reranking	candidata aceitável aparece, mas fica abaixo de distratores
B - bundle	seleção omite comportamento, inclui redundância/conflito ou viola ordem necessária
M - menu	tool necessária ausente ou menu incompatível com a condição
T - execução	argumento, sequência ou uso de tool incorreto
S - estado	resultado intermediário perdido, projetado incorretamente ou não reutilizado
V - revisão	trigger ausente/excessivo, preservação violada ou plano revisado incorreto
F - entrega final	componentes corretos, mas empacotamento não satisfaz critérios ou duplica síntese

Fonte: elaboração própria (2026).

Na categoria T, o subtipo T-E identifica falhas de evidência: retorno executável omitido, duplicado, não correlacionado ou fora de ordem; inclusão indevida da tool terminal; ou materialização divergente da decisão e das observações. Na categoria V, o subtipo V-E identifica uma revisão sem observação, com conjunto incompleto de observações, em ordem não determinística ou com identificadores internos expostos ao planner. Esses subtipos distinguem defeitos do runtime de erro semântico do modelo.

O sufixo S identifica falha na fronteira de saída estruturada do estágio correspondente. Se o runtime muda estado após uma submissão localmente inválida, deixa de fornecer feedback dentro do orçamento ou aceita uma violação do contrato completo, a causa é de runtime. Se a fronteira preserva estado e esgota corretamente o orçamento após respostas repetidamente

inválidas, o resultado é atribuído ao estágio cognitivo que não produziu uma correção conforme, não à infraestrutura.

11.2 Primeiro desvio do conjunto aceitável

A atribuição principal marca o primeiro estágio cuja correção contrafactual recupera uma trajetória aceitável. O procedimento é operacional:

1. execute a condição e identifique uma falha end-to-end; 2. substitua o plano produzido por `oracle-plan`, mantendo os estágios posteriores; 3. se a execução for recuperada, atribua P; se não, restaure o plano original; 4. repita, na ordem, com `oracle-retrieval`, `oracle-bundle`, `oracle-menu` e `oracle-state`; 5. atribua o primeiro estágio cuja substituição recupera o caso; 6. se nenhum oracle recuperar, atribua T ou F conforme o trace de execução e entrega.

Quando uma candidata aceitável aparece na shortlist, mas é ordenada abaixo de distratores e por isso não entra no bundle, a categoria é K. Quando o reranking é adequado e o seletor rejeita indevidamente a candidata, a categoria é B. Erros secundários podem ser registrados, mas o relatório separa causa inicial e sintomas. A análise qualitativa usa amostras estratificadas de sucessos e falhas, não apenas casos extremos.

12 CRITÉRIOS DE DECISÃO

12.1 O que sustenta cada claim

Quadro 15 - Evidência mínima para sustentar as reivindicações

Claim	Evidência esperada
C1	M1 melhora cobertura ou dependências e reduz sobredecomposição em relação a B2, com intervalo compatível com efeito relevante.
C2	A1 mostra ganho consistente de body-aware em retrieval e esse ganho se propaga para bundle ou sucesso em casos ambíguos.
C3	M1 supera top-1 em cobertura comportamental e top-k em redundância, mantendo ou elevando sucesso.
C4	Objetivos de classe B têm sucesso em M1 e perdem desempenho na ablação sem T_{base} .
C5	Casos com revisão esperada apresentam maior recovery rate, sem modificar objetivos concluídos.
C6	M1 supera o baseline pré-definido nas classes composicionais; custo é quantificado e não ocultado.

Fonte: elaboração própria (2026).

12.2 Resultados que enfraquecem a arquitetura

- planos por objetivos não reduzem nós mecânicos ou perdem cobertura;
- body-aware melhora ranking, mas não altera bundles nem sucesso;
- bundles seletivos não superam top-1 ou acumulam conflito e custo;
- Tbase global resolve tudo e a associação de tools ao bundle não acrescenta valor observável;
- revisão localizada aciona mudanças excessivas ou não recupera casos adaptativos;
- o ganho end-to-end desaparece ao controlar modelo, prompt e orçamento.

Esses resultados não devem ser reinterpretados como sucesso. A consequência de design pode ser remover ou restringir um mecanismo. O protocolo existe para permitir essa decisão, não para confirmar o artigo por construção.

13 AMEAÇAS À VALIDADE

Quadro 16 - Ameaças e controles

Ameaça	Controle
Validade de construção	Métricas podem premiar um plano textual sem refletir resultado real. Mitigação: combinar matching, trace e verificadores.
Validade interna	Condições podem diferir em prompt ou orçamento além do mecanismo testado. Mitigação: configuração compartilhada, matriz de condições e ablações de uma variável.
Validade externa	Quatro domínios e catálogo curado não representam todo o ecossistema. Mitigação: replicação com catálogo maior e segundo conjunto de domínios.
Dependência do modelo	Um modelo forte pode mascarar routing; um modelo fraco pode não seguir bundles. Mitigação: reportar pelo menos duas classes de modelo na replicação.
Ambiguidade do gold	Planos e bundles têm múltiplas soluções. Mitigação: comportamentos explícitos, alternativas, dupla anotação e adjudicação.
Vazamento	Templates ou bodies podem revelar casos. Mitigação: splits por família, catálogo congelado e auditoria de sobreposição.
Viés do avaliador	A condição pode ser inferida pelo estilo. Mitigação: anonimizar, randomizar e usar critérios observáveis.
Não independência	Repetições do mesmo caso são correlacionadas. Mitigação: efeitos mistos ou bootstrap por caso.
Não conformidade	Uma implementação pode chamar-se MOSAIC sem respeitar o perfil. Mitigação: executar a suíte de conformidade antes do benchmark.

Fonte: elaboração própria (2026).

14 PACOTE DE REPRODUTIBILIDADE

A entrega mínima da validação deve conter:

- protocolo pré-registrado e histórico de alterações;
- suíte de testes de contrato e resultados de conformidade;
- dataset de casos com split, versões e hashes;
- catálogo de skills, `skill_behavior_map` e cópia canônica dos `SKILL.md`;
- registro de tools, schemas, fixtures e Tbase por condição;
- prompts e configurações completas;
- traces brutos imutáveis e resultados de verificadores;
- anotações humanas, acordo e decisões de adjudicação;
- scripts de scoring e notebook de análise;
- tabelas e figuras geradas a partir dos dados, não editadas manualmente;
- relatório de limitações, exclusões e falhas de infraestrutura.

Cada arquivo derivado deve apontar para a versão das entradas que o produziu. O relatório final deve ser regenerável a partir do pacote, sem depender de valores copiados manualmente.

15 CHECKLIST OPERACIONAL DO ESTUDO

Quadro 17 - Checklist por marco

Marco	Condição de saída
Antes da conformidade	Schemas, registro, DAG, menu, correlação, status e compositor testados.
Antes do piloto	Claims e RQs fechadas; trace e verificadores funcionando; suíte MOSAIC 0.2 aprovada.
Antes do freeze	Golds adjudicados; concordância aceitável; prompts, hiperparâmetros e análise definidos.
Antes da execução	Hashes registrados; ambiente limpo; ordem randomizada; monitoramento de falhas técnicas.
Antes do scoring	Traces completos; observações automáticas auditadas; exclusões documentadas; verificadores congelados.
Antes do relatório	Contraste primário executado; intervalos e efeitos reportados; erros causais auditados.
Antes da publicação	Pacote reproduzível; claims revisadas conforme evidência; resultados negativos preservados.

Fonte: elaboração própria (2026).

16 CONSIDERAÇÕES FINAIS

A validação proposta mantém a mesma regra de redução do MOSAIC 0.2: medir somente o que é necessário para testar a tese arquitetural. O estudo não precisa incorporar segurança, execução distribuída, aprendizagem online ou otimização formal de bundles. Precisa, porém, separar conformidade de desempenho, distinguir decisões semânticas de evidência criada pelo runtime, preservar traces e admitir múltiplas soluções corretas. O protocolo transforma a arquitetura em claims falsificáveis e uma suíte de conformidade que verifica captura automática, correlação, ordem, materialização e associação integral das observações à revisão sem exigir IDs reproduzidos pelo modelo. Planejamento, retrieval, bundle, menu, estado, evidência, revisão e sucesso final são avaliados em níveis distintos; baselines e ablações permitem atribuir efeitos; oráculos operacionalizam o primeiro desvio causal; o piloto corrige instrumentos antes do conjunto final; e a análise por execução evita descartar a variabilidade entre repetições. O objetivo empírico não é provar que mais componentes são melhores. É identificar o menor conjunto de decisões que produz ganho observável nas tarefas para as quais a composição foi proposta.

REFERÊNCIAS

AGENT SKILLS. **Specification**. [S. l.], 2026. Disponível em: <https://agentskills.io/specification>. Acesso em: 29 jul. 2026. BABU, Rahul Suresh; IYER, Laxmipriya

Ganesh. ToolMenuBench: benchmarking tool-menu filtering strategies for reliable and efficient LLM agents. **arXiv**, 2026. DOI: 10.48550/ar-Xiv.2606.15508. CHO, Hongcheol; KANG, Ryangkyung; KIM, Youngeun. SkillRet: a large-scale benchmark for skill retrieval in LLM agents. **arXiv**, 2026. DOI: 10.48550/arXiv.2605.05726.

EFRON, Bradley; TIBSHIRANI, Robert J. **An introduction to the bootstrap**. New York: Chapman & Hall, 1993. GAO, Xueping. Compositional skill routing for LLM agents: decompose, retrieve, and compose. **arXiv**, 2026. DOI: 10.48550/arXiv.2606.18051. GONG, Jingzhi et al. SkillMOO: multi-objective optimization of agent skills for software engineering. **arXiv**, 2026. DOI: 10.48550/arXiv.2604.09297. HOLM, Sture. A simple sequentially rejective multiple test procedure. **Scandinavian Journal of Statistics**, v. 6, n. 2, p. 65-70, 1979. KRIPPENDORFF, Klaus. **Content analysis: an introduction to its methodology**. 4. ed. Thousand Oaks: SAGE, 2018. LI, Xiangyi et al. SkillsBench: benchmarking how well agent skills work across diverse tasks. **arXiv**, 2026. DOI: 10.48550/arXiv.2602.12670. MCNEMAR, Quinn. Note on the sampling error of the difference between correlated proportions or percentages. **Psychometrika**, v. 12, p. 153-157, 1947. WILCOXON, Frank. Individual comparisons by ranking methods. **Biometrics Bulletin**, v. 1, n. 6, p. 80-83, 1945. YAO, Shunyu et al. ReAct: synergizing reasoning and acting in language models. In: INTERNATIONAL CONFERENCE ON LEARNING REPRESENTATIONS, 2023. **Proceedings [...]** [S. l.]: ICLR, 2023. DOI: 10.48550/arXiv.2210.03629. ZHENG, YanZhao et al. SkillRouter: retrieve-and-rerank skill selection for LLM agents at scale. **arXiv**, 2026. DOI: 10.48550/arXiv.2603.22455.

APÊNDICE A - MODELO DE FICHA DE CASO

Case ID:
 Versão:
 Pedido:
 Domínio:
 Objetivo focal:
 Classe de composição:
 Dificuldade:
 Requer revisão:
 Requisito de tool:
 Ambiente inicial:
 T_base da condição:
 Resultados obrigatórios:
 Planos aceitáveis:
 Dependências aceitáveis:
 Comportamentos obrigatórios por papel:
 Comportamentos opcionais por papel:
 Comportamentos proibidos por papel:

Restrições de ordem:
 Bundles aceitáveis por papel (opcional):
 Tools necessárias / opcionais:
 Divisões mecanísticas proibidas:
 Observação de revisão (se houver):
 Critérios determinísticos:
 Rubrica humana:
 Notas de adjudicação:

A ficha deve registrar alternativas e restrições explícitas, não observações vagas como “resposta razoável”. Todo critério precisa indicar como será verificado.

APÊNDICE B - RELATÓRIO POR CONDIÇÃO

Quadro B.1 - Resumo mínimo de resultados

Dimensão	Resultado a reportar
Conformidade	testes aprovados, falhas e versão do perfil
Cobertura	número de casos, execuções válidas e exclusões
Primário	sucesso end-to-end por execução, efeito, intervalo de 95% e modelo misto
Planejamento	cobertura, sobre/subdecomposição, F1 de dependências
Routing	Recall@K, MRR, nDCG@K e ablação de body
Bundle	F1/Jaccard, cobertura, redundância, conflito, ordem e tamanho
Tools	recall do menu, overhead, chamadas incorretas e reuso
Estado e revisão	projeção, trigger, correção, preservação e recovery rate
Eficiência	tokens, chamadas, passos, latência e custo por sucesso
Erros	distribuição por primeiro estágio causal
Estratos	resultados por classe, domínio, dificuldade, revisão e modelo

Fonte: elaboração própria (2026).

APÊNDICE C - DECISÕES PRÉ-REGISTRADAS

- condição e contraste primários; • métrica primária e critérios de sucesso; • Kretrieve, Khint, Kmax, Tbase, Lnode, Rmax e orçamento; • número de repetições e uso descritivo do caso agregado; • procedimento de matching e adjudicação; • regra de rerun e exclusão; • modelo estatístico e correção de multiplicidade; • regra de congelamento após o piloto; • quais análises são confirmatórias e quais são exploratórias; • procedimento de atribuição causal por oráculos.

APÊNDICE D - CONFORMIDADE MOSAIC 0.2

Quadro D.1 - Casos mínimos de conformidade da MOSAIC 0.2

ID	Caso	Propriedade verificada
D01	<code>allowed-tools</code> como lista YAML	normalização canônica
D02	skill duplicada ou tool inexistente	carregamento falha
D03	plano com ciclo	validação falha
D04	bundle vazio sem tool	objetivo cognitivo conclui
D05	bundle vazio com tool base e fixture oculta	classe B conclui e falha sem T_{base}
D06	uma skill com várias tools	menu contém a união correta
D07	várias skills compartilhando tool	deduplicação do menu
D08	empate de reranking	desempate determinístico
D09	ramo de estado irrelevante	projeção omite entrada não causal
D10	decisão <code>completed</code> sem tool	conclusão válida com zero observações
D11	decisão <code>completed</code> após uma tool	retorno é capturado automaticamente
D12	decisão <code>completed</code> após várias tools	todas as observações aparecem na ordem dos resultados
D13	chamada sem retorno	falha de runtime
D14	IDs de chamada ou resultados duplicados	falha de runtime
D15	resultado sem chamada correlacionada	falha de runtime
D16	tool terminal de saída estruturada	não aparece em <code>observations</code>
D17	<code>needs_revision</code> sem observação	falha de runtime
D18	três tools; evidência invalidante no meio	planner recebe as três observações em ordem
D19	saída do modelo com <code>observationRefs</code>	schema rejeita campo legado
D20	pedido com <code>triggerObservationRef</code>	schema rejeita campo legado
D21	prompt de revisão localizado	contém nome, entrada e saída de toda evidência, sem <code>callId</code>
D22	revisões concorrentes	ordem da wave é determinística e nós concluídos são preservados
D23	limite de revisão atingido	execução termina sem ciclo infinito
D24	objetivo terminal de redação	compositor não chama o modelo novamente
D25	provider aceita resposta que viola invariante local	runtime preserva estado, fornece feedback e aceita a correção ou falha ao esgotar o orçamento

Fonte: elaboração própria (2026).